
TRƯỜNG ĐẠI HỌC PHENIKAA
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN LIÊN NGÀNH

Nhóm 5

SMALLCAP-Vi: Phát triển mô hình sinh ảnh tiếng Việt nhẹ sử dụng caption truy xuất làm gợi ý

Họ và tên	MSSV	Email
Lê Thị Hồng Duyên	22014455	22014455@st.phenikaa-uni.edu.vn
Lê Thị Ly	22010272	22010272@st.phenikaa-uni.edu.vn

Giảng viên hướng dẫn: TS.Đặng Thị Thuý An

Hà Nội, Tháng 7 năm 2025

Bảng phân công nhiệm vụ

Tên thành viên	Mã sinh viên	Nhiệm vụ	Đóng góp
Lê Thị Hồng Duyên	22014455	Tìm hiểu paper Sửa mã nguồn Fine turning mô hình Train mô hình Viết báo cáo Làm silde thuyết trình	50%
Lê Thị Ly	22010272	Tìm hiểu paper Sửa mã nguồn Train mô hình Viết báo cáo Làm silde thuyết trình	50%

Mục lục

1. Giới thiệu4

1.1 Đặt vấn đề.....4

1.2 Các giải pháp đã có4

1.3 Giải pháp đề xuất.....5

2. Thiết kế và triển khai.....5

2.1 Các yêu cầu chức năng5

2.2 Các yêu cầu phi chức năng.....6

2.3 Các ràng buộc (Constraints)6

2.3.1 Triển khai6

2.3.2 Các ràng buộc kinh tế6

2.3.3 Các ràng buộc về đạo đức.....7

2.4 Mô hình hệ thống / Thiết kế giải pháp7

2.4.1 Cơ sở lý thuyết.....7

2.4.2 Kiến trúc mô hình17

2.4.3 Huấn luyện mô hình.....18

2.4.4 Thực nghiệm20

3. Một số thành phần khác của đề án26

3.1 Kế hoạch dự án.....26

3.2 Đảm bảo thực hiện đúng làm việc nhóm.....27

3.3 Các vấn đề về đạo đức và làm việc chuyên nghiệp.....27

3.4 Tác động xã hội28

4. Kết luận.....28

5. Tài liệu tham khảo29

Danh mục hình ảnh

Hình 1: Cross-Attention12

Hình 2: Kiến trúc mô hình SMALLCAP-Vi17

Hình 3: Định dạng dữ liệu chuẩn Karpathy19

Hình 4: Kết quả huấn luyện20

Hình 5: Demo với ảnh có chủ đề tennis22

Hình 6: Demo với ảnh có chủ đề liên quan đến bóng đá24

Hình 7: Demo với ảnh có chủ đề bất kỳ25

Hình 8: Demo với ảnh có chủ đề bóng chày25

1. Giới thiệu

1.1 Đặt vấn đề

Tạo chú thích ảnh (image captioning) là một bài toán thị giác–ngôn ngữ quan trọng, trong đó mục tiêu là sinh ra một câu văn ngắn gọn, tự nhiên và chính xác để mô tả nội dung và ngữ cảnh của một bức ảnh tĩnh. Đây là bài toán đòi hỏi sự hiểu biết sâu sắc cả về đặc trưng hình ảnh và ngữ nghĩa văn bản – từ đó kết hợp chúng để tạo ra ngôn ngữ mô tả phù hợp. Trong thực tiễn, mô tả ảnh có ứng dụng rộng rãi trong nhiều lĩnh vực như: Trợ lý giọng nói, Hỗ trợ người khiếm thị, Tìm kiếm và truy vấn hình ảnh bằng văn bản (multimodal retrieval).

Hiện nay kết quả tốt nhất trong lĩnh vực tạo chú thích ảnh được tạo ra bởi các mô hình có quy mô ngày càng lớn và được huấn luyện trên các bộ dữ liệu có quy mô ngày càng tăng. Việc mở rộng quy mô dẫn đến yêu cầu tính toán cao hơn cho quá trình huấn luyện sơ cấp và tinh chỉnh mô hình. Điều này trở nên đặc biệt quan trọng khi cần nhiều phiên bản mô hình khác nhau cho các miền thị giác khác nhau và cho người dùng cuối trong các ứng dụng thực tế. Một số mô hình như ClipCap, I-Tuning được đưa ra nhằm giảm chi phí huấn luyện. Những mô hình này sử dụng một bộ mã hóa thị giác và bộ giải mã ngôn ngữ đã được huấn luyện sẵn. Các tham số của những thành phần được huấn luyện sẵn này được giữ cố định và chỉ có phần ánh xạ giữa hai thành phần được huấn luyện cho tác vụ tạo chú thích ảnh. Cách tiếp cận này dẫn đến số lượng tham số cần huấn luyện giảm đáng kể và thời gian huấn luyện nhanh hơn. Tuy các mô hình này hoạt động ở quy mô dễ quản lý hơn về mặt nghiên cứu, nhưng chúng vẫn có thể không phù hợp với các ứng dụng thực tế đã đề cập ở trên, vì cả hai mô hình đều yêu cầu huấn luyện riêng cho từng trường hợp sử dụng.

Trong dự án này chúng tôi giới thiệu SMALLCAP-VI, một mô hình tạo chú thích ảnh cho ngôn ngữ Tiếng Việt được kích hoạt bằng các chú thích được truy xuất từ một kho văn bản bên ngoài, dựa trên hình ảnh đầu vào. Cách tiếp cận này trong việc tạo chú thích ảnh mang lại nhiều đặc điểm mong muốn: huấn luyện nhẹ, chuyển đổi miền không cần huấn luyện, và khai thác dữ liệu lớn mà không cần huấn luyện.

1.2 Các giải pháp đã có

Các phương pháp hiện đại trong tạo chú thích hình ảnh sử dụng kiến trúc encoder-decoder, trong đó một ảnh đầu vào được đưa vào visual encoder và một chú thích được tạo ra bởi language decoder theo kiểu autoregressive. Hiện nay kết quả tốt nhất thuộc về các mô hình vision-and-language (V&L) models. Những mô hình quy mô lớn này được huấn luyện sơ cấp trên một lượng lớn cặp dữ liệu hình ảnh–văn bản để học các đặc trưng đa phương thức tổng quát. Sau đó, chúng có thể được tinh chỉnh (finetune) cho các tác vụ hạ nguồn như tạo chú thích ảnh, tuy nhiên cần có một mô hình được tối ưu riêng biệt cho mỗi bộ dữ liệu tạo chú thích ảnh. Do đó, những mô hình này đòi hỏi nguồn lực rất lớn cho cả quá trình huấn luyện và triển khai.

Các thành phần của mô hình tạo chú thích ảnh có thể được khởi tạo bằng trọng số đã huấn luyện trước và được giữ cố định một phần hoặc toàn bộ như một cách để

ngăn chặn hiện tượng *catastrophic forgetting*, tức là giúp duy trì khả năng khái quát hóa tốt. Vì các tham số của mô hình bị đóng băng không cần cập nhật gradient, quá trình huấn luyện trở nên nhanh hơn và tiêu tốn ít bộ nhớ GPU hơn. ClipCap và I-Tuning là hai mô hình tạo chú thích ảnh với huấn luyện nhẹ, sử dụng một bộ visual encoder CLIP và language decoder GPT-2 như các thành phần mô hình được giữ cố định. Để kết nối giữa hai thành phần được huấn luyện độc lập này, ClipCap sử dụng kỹ thuật prefix-tuning, ánh xạ embedding có độ dài cố định từ CLIP sang không gian ngôn ngữ của GPT-2. Trong khi đó, I-Tuning trích xuất các embedding bộ nhớ thị giác từ CLIP và sử dụng chúng để điều chỉnh các trạng thái ẩn đầu ra của GPT-2.

Retrieval-augmented language generation là quá trình tạo văn bản dựa trên thông tin bổ sung được truy xuất từ một kho dữ liệu bên ngoài. Phương pháp này đã thu hút nhiều sự quan tâm trong các tác vụ khác nhưng vẫn còn ít được khai thác trong lĩnh vực chú thích ảnh. Một nghiên cứu gần đây đã đề xuất các mô hình chú thích dựa trên transformer có Retrieval-augmented, trong đó thực hiện cơ chế cross-attention trên các chú thích đã được mã hóa và truy xuất.

1.3 Giải pháp đề xuất

Trong dự án này chúng tôi đề xuất mô hình SMALLCAP-Vi, một mô hình tạo chú thích tiếng Việt dựa trên hình ảnh đầu vào và các chú thích có liên quan được truy xuất từ một kho dữ liệu. Mô hình của chúng tôi nhẹ và huấn luyện nhanh, vì các tham số được học chỉ nằm trong các lớp cross-attention mới được thêm vào giữa bộ mã hóa CLIP đã được huấn luyện trước và bộ giải mã GPT2-Vietnamese. Nhờ vào cơ chế truy xuất, mô hình có thể tận dụng dữ liệu bên ngoài và do đó cần lưu trữ ít thông tin hơn trong trọng số của mình. SMALLCAP-Vi cũng có khả năng khai thác dữ liệu theo cách không cần huấn luyện. Một khi mô hình đã được huấn luyện, chúng ta có thể thay thế kho dữ liệu bằng: (i) các chú thích từ một miền mới hoặc (ii) một tập hợp lớn và đa dạng các chú thích. Trong trường hợp thứ nhất, đóng vai trò như một giải pháp thay thế cho việc tinh chỉnh (finetuning), SMALLCAP-Vi có thể tiếp cận phong cách và các khái niệm đặc trưng của miền mới và tạo ra các chú thích phù hợp. Trong trường hợp thứ hai, như một giải pháp thay thế cho tiền huấn luyện tổng quát, SMALLCAP-Vi có thể tiếp cận tri thức chung và áp dụng nó cho bất kỳ miền nào. SMALLCAP-Vi có hiệu năng tương đương với các mô hình huấn luyện nhẹ khác trên các đánh giá trong miền, và vượt trội hơn nhiều khi đánh giá ngoài miền. Mô hình này vượt qua một hạn chế quan trọng của các mô hình trước đây, vốn yêu cầu tinh chỉnh rõ ràng để thích ứng với các miền mới, và bằng cách đó cho thấy tiềm năng của phương pháp retrieval augmentation trong các tác vụ đa phương thức.

2. Thiết kế và triển khai

2.1 Các yêu cầu chức năng

Hệ thống SMALLCAP-Vi được thiết kế nhằm mục tiêu mang lại khả năng mô tả ảnh tự động bằng tiếng Việt, với giao diện đơn giản và quy trình vận hành hiệu quả. Các yêu cầu chức năng cụ thể bao gồm:

- Tải ảnh đầu vào: Người dùng có thể tải ảnh từ hệ thống, với định dạng được hỗ trợ gồm: .jpg, .jpeg, .png.

- Sinh caption tiếng Việt: Hệ thống sẽ thực hiện sinh câu mô tả ngữ cảnh ảnh bằng tiếng Việt.

- Tích hợp truy xuất caption bằng FAISS: Trước khi sinh caption, hệ thống sử dụng FAISS để truy xuất k caption tương tự nhất từ tập huấn luyện dựa trên embedding ảnh. Các caption truy xuất này được cung cấp như ngữ cảnh gợi ý (prompt) cho mô hình sinh caption.

- Hiện thị kết quả: Cả caption sinh bởi mô hình và các caption được truy xuất sẽ được hiện thị để người dùng dễ dàng so sánh.

2.2 Các yêu cầu phi chức năng

- Mô hình phải nhẹ, có thể chạy trên GPU 8GB, thời gian sinh caption ≤ 1 giây/ảnh trên GPU

- Hỗ trợ thêm dữ liệu mới, cập nhật index FAISS nhanh chóng không cần huấn luyện lại từ đầu và Cho phép plug-in các kiến trúc encoder/decoder khác mà không thay đổi toàn bộ pipeline.

- Toàn bộ pipeline từ tiền xử lý đến inference có script cụ thể, dễ dàng tái chạy. Checkpoint mô hình và FAISS index có thể tái sử dụng qua các lần chạy khác nhau.

- Có notebook Colab tối ưu cho inference thử nghiệm nhanh.

2.3 Các ràng buộc (Constraints)

2.3.1 Triển khai

a. Hạn chế tài nguyên tính toán

Mô hình cần tối ưu để triển khai trên phần cứng phổ biến (GPU 8GB hoặc CPU thông thường). Không sử dụng các mô hình quá lớn

b. Khả năng triển khai thực tế

Phải cung cấp phương thức triển khai đơn giản qua notebook Colab và Hạn chế phụ thuộc vào hạ tầng phức tạp như Kubernetes, máy chủ đa GPU chuyên dụng.

c. Yêu cầu tương thích phần mềm

Sử dụng các thư viện mã nguồn mở phổ biến (PyTorch, Hugging Face, FAISS) không phụ thuộc vào các API trả phí từ bên thứ ba.

d. Thời gian phát triển

Hoàn thiện MVP (sản phẩm khả thi tối thiểu) trong 2-3 tháng

2.3.2 Các ràng buộc kinh tế

a. Chi phí triển khai thấp

Ưu tiên sử dụng tài nguyên máy tính miễn phí (Google Colab, server GPU trường học). Tối thiểu hóa chi phí inference để có thể triển khai trên server giá rẻ hoặc offline.

b. Giới hạn chi phí đào tạo mô hình

Không yêu cầu huấn luyện từ đầu trên tập dữ liệu lớn, tận dụng mô hình pre-trained và fine-tune nhẹ

2.3.3 Các ràng buộc về đạo đức

a. Tôn trọng quyền riêng tư dữ liệu

Không sử dụng dữ liệu cá nhân, ảnh có thông tin định danh mà không có sự đồng ý. Dữ liệu thu thập từ internet phải từ các nguồn công khai có giấy phép phù hợp.

b. Tránh thiên vị (Bias)

Đánh giá mô hình kỹ lưỡng để giảm thiên vị về giới tính, sắc tộc, vùng miền trong caption sinh ra. Có quy trình kiểm tra caption đầu ra, đặc biệt khi mô hình sử dụng truy xuất caption.

c. Không triển khai mô hình vào các ứng dụng tạo nội dung sai lệch, lừa đảo hoặc vi phạm pháp luật. Có cảnh báo rõ ràng về khả năng sai lệch (bias/hallucination) của mô hình.

2.4 Mô hình hệ thống / Thiết kế giải pháp

2.4.1 Cơ sở lý thuyết

a. CLIP-Vision

CLIP (Contrastive Language-Image Pre-training) là một mô hình đa phương thức được huấn luyện để hiểu mối quan hệ giữa văn bản và hình ảnh. CLIP-Vision là thành phần thị giác của mô hình CLIP, có khả năng trích xuất các đặc trưng hình ảnh mạnh mẽ.

Trong SmallCap, CLIP-Vision được tái sử dụng (hay sử dụng lại) để mã hóa một ảnh đầu vào (I) thành một chuỗi các đặc trưng thị giác (visual embedding sequence). Điều này có nghĩa là, thay vì chỉ tạo ra một vector đặc trưng duy nhất cho toàn bộ ảnh, CLIP-Vision ở đây tạo ra một chuỗi các vector $(v_1, v_2, \dots, v_T)$. Mỗi vector trong chuỗi này có thể đại diện cho một phần (patch) hoặc một vùng (region) cụ thể của ảnh.

Việc sử dụng CLIP-Vision giúp mô hình "nhìn thấy" và "hiểu được" được nội dung hình ảnh ở nhiều cấp độ chi tiết khác nhau. Các vector đặc trưng này chính là nguồn thông tin hình ảnh đầu vào cho bộ giải mã ngôn ngữ (decoder), giúp mô hình tạo ra các chú thích (caption) phù hợp với nội dung hình ảnh.

Công thức:

$$V = [v_1, v_2, \dots, v_T] = \text{CLIP} - \text{Vision}(I) \quad (1)$$

Trong đó:

I : ảnh đầu vào

V : chuỗi các nhúng thị giác (visual embedding)

v_i : một nhúng thị giác riêng lẻ tại vị trí i

T : số lượng patch/region mà CLIP-Vision trích xuất được từ ảnh

d : chiều của mỗi vector nhúng (v_1), tức là $V \in \mathbb{R}^{T \times d}$

b. CLIP-Text

CLIP (Contrastive Language-Image Pre-training) là một mô hình học sâu được phát triển bởi OpenAI, được huấn luyện để hiểu mối quan hệ ngữ nghĩa giữa hình ảnh và văn bản. Nó bao gồm hai thành phần chính: một bộ mã hóa hình ảnh (Vision Encoder, như đã nói ở CLIP-Vision) và một bộ mã hóa văn bản (Text Encoder). CLIP-Text được huấn luyện để tạo ra các biểu diễn vector (embeddings) cho văn bản sao cho các vector của văn bản và hình ảnh có liên quan về mặt ngữ nghĩa sẽ nằm gần nhau trong không gian đặc trưng chung. Quá trình huấn luyện sử dụng một nhiệm vụ học đối lập (contrastive learning), trong đó mô hình được yêu cầu phân biệt các cặp hình ảnh-văn bản khớp với các cặp không khớp.

CLIP-Text có chức năng biến đổi một đoạn văn bản (ví dụ: một câu, một cụm từ, hoặc một đoạn mô tả) thành một vector số học (text embedding). Vector này mã hóa ý nghĩa ngữ nghĩa của văn bản đó.

Tác dụng:

- **Tìm kiếm đa phương thức (Cross-modal Search):** Khi có một text embedding và một tập hợp các image embeddings, bạn có thể tìm kiếm hình ảnh phù hợp nhất với mô tả văn bản bằng cách tìm kiếm image embedding gần nhất với text embedding trong không gian chung. Ngược lại, bạn cũng có thể tìm kiếm văn bản phù hợp nhất với một hình ảnh.
- **Phân loại zero-shot (Zero-shot Classification):** CLIP-Text cho phép phân loại hình ảnh mà không cần huấn luyện lại trên các lớp mới. Bằng cách mã hóa tên của các lớp thành text embeddings và so sánh chúng với image embeddings, mô hình có thể gán hình ảnh vào lớp có mô tả văn bản tương đồng nhất.
- **Tạo nhúng cho Datastore:** Trong bối cảnh của "SmallCap", nếu Datastore không chỉ chứa cặp ảnh-caption mà còn cần khả năng truy xuất dựa trên văn bản hoặc cần so sánh độ tương đồng ngữ nghĩa giữa các caption, thì CLIP-Text có thể được sử dụng để tạo ra các embedding cho các caption đó.
- **Đo lường sự tương đồng ngữ nghĩa:** Có thể tính toán độ tương đồng giữa hai đoạn văn bản bằng cách đo khoảng cách cosine giữa các text embeddings của chúng.

Công thức (Không trực tiếp cho CLIP-Text, nhưng là khái niệm chung về nhúng): Giả sử T là một đoạn văn bản đầu vào.

$$E_T = CLIP - Text(T) \quad (2)$$

Trong đó:

- E_T : Vector nhúng của đoạn văn bản T.
- $E_T \in R^k$, với k là chiều của không gian embedding (thường là 512, 768, hoặc 1024 tùy thuộc vào phiên bản CLIP).

Khi so sánh với image embedding E_I (từ CLIP-Vision), người ta thường dùng độ tương đồng cosine:

$$Similarity(E_T, E_I) = \frac{E_T * E_I}{\|E_T\| * \|E_I\|} \quad (3)$$

Giá trị này càng gần 1, hai nhúng càng giống nhau về mặt ngữ nghĩa.

c. Datastore

Datastore là một khái niệm trong các hệ thống truy xuất thông tin, nơi lưu trữ một tập hợp lớn các cặp dữ liệu đã được tiền xử lý để phục vụ cho việc tìm kiếm hoặc tham khảo. Trong bối cảnh này, nó được dùng để lưu trữ các cặp ảnh-chú thích.

Datastore chứa một tập hợp lớn các cặp ảnh và chú thích tương ứng bằng tiếng Việt. Các chú thích này có thể đã được "pre-tokenized" (tiền mã hóa thành các token) bằng các phương pháp như BPE (Byte Pair Encoding) hoặc SentencePiece, thường là từ một mô hình ngôn ngữ đã được huấn luyện trước như GPT-2 Vietnamese.

Tác dụng:

Huấn luyện: Cung cấp dữ liệu huấn luyện cho mô hình.

Truy xuất: Trong quá trình sinh chú thích, datastore sẽ được sử dụng để truy xuất các chú thích tương tự với ảnh đầu vào (dựa trên sự tương đồng của ảnh), và các chú thích được truy xuất này sẽ đóng vai trò là "prompt" ban đầu cho bộ giải mã ngôn ngữ. Điều này giúp mô hình sinh ra các chú thích có tính liên quan và chất lượng cao hơn.

d. GPT2-Vietnamese

GPT-2 (Generative Pre-trained Transformer 2) là một mô hình ngôn ngữ dựa trên kiến trúc Transformer, được huấn luyện để sinh văn bản. "GPT-2 Vietnamese Decoder" là một phiên bản của GPT-2 đã được huấn luyện với dữ liệu tiếng Việt, ví dụ như mô hình gpt2.vietnamese.vocab117m từ NlpHUST. Mô hình này ban đầu được huấn luyện để dự đoán từ tiếp theo trong một chuỗi.

Chức năng:

- Sinh caption: Thành phần này đóng vai trò là bộ giải mã chính để sinh ra chú thích (caption) cho ảnh.
- Fine-tuning: Nó được fine-tune lại (tinh chỉnh) trên nhiệm vụ sinh chú thích ảnh.
- Sử dụng prompt: Điểm đặc biệt là nó sử dụng caption được truy xuất từ Datastore làm "prompt" ban đầu. Điều này có nghĩa là bộ giải mã sẽ bắt đầu sinh văn bản dựa trên một chú thích đã có sẵn và liên quan, thay vì bắt đầu từ con số 0.
- Thêm Cross-Attention: Để kết nối với thông tin hình ảnh, hai khối Cross-Attention được thêm vào kiến trúc của GPT-2 Vietnamese Decoder. Các khối này cho phép bộ giải mã tiếp nhận và xử lý các đặc trưng hình ảnh từ CLIP-Vision.

Tác dụng:

- Tận dụng sức mạnh của mô hình ngôn ngữ đã được huấn luyện trước (GPT-2 Vietnamese) để sinh ra văn bản mạch lạc và tự nhiên.
- Việc sử dụng chú thích truy xuất làm prompt giúp định hướng quá trình sinh caption, đảm bảo tính liên quan và chất lượng của chú thích đầu ra.
- Thêm Cross-Attention là cầu nối quan trọng giúp mô hình kết hợp thông tin thị giác và ngôn ngữ, cho phép chú thích được tạo ra phản ánh đúng nội dung hình ảnh.

e. FAISS

FAISS là một thư viện mã nguồn mở được phát triển bởi Facebook AI, được thiết kế để tìm kiếm hiệu quả và nhanh chóng các vector tương tự trong các tập dữ liệu lớn. Các phương pháp tìm kiếm truyền thống trên tập vector lớn (ví dụ: tìm vector gần nhất trong không gian Euclidean) có thể rất chậm nếu thực hiện brute-force (kiểm tra từng cặp). FAISS cung cấp các thuật toán xấp xỉ (Approximate Nearest Neighbor - ANN) và chính xác (Exact Nearest Neighbor) để giải quyết vấn đề này.

FAISS cung cấp các thuật toán và cấu trúc dữ liệu để lưu trữ và tìm kiếm các vector có chiều cao lớn (high-dimensional vectors) một cách cực kỳ hiệu quả, dựa trên độ tương đồng (ví dụ: khoảng cách Euclidean, độ tương đồng cosine).

Tác dụng:

- Tìm kiếm lân cận gần nhất (Nearest Neighbor Search): Đây là ứng dụng chính. Khi bạn có một vector truy vấn (ví dụ: một image embedding hoặc text embedding) và muốn tìm các vector tương tự nhất trong một tập dữ liệu lớn (ví dụ: các embeddings của ảnh hoặc caption trong Datastore), FAISS giúp thực hiện điều này với tốc độ cao.
- Xây dựng Datastore hiệu quả: Trong bối cảnh của "SmallCap", nếu Datastore lưu trữ các embedding của ảnh hoặc caption, FAISS có thể được sử dụng để lập chỉ mục (index) các embedding này. Khi cần truy xuất các caption liên quan đến một ảnh đầu vào, bạn sẽ dùng image embedding của ảnh đó làm truy

vấn và FAISS sẽ nhanh chóng trả về các nhúng (và do đó là các caption tương ứng) gần nhất.

- Giảm chiều dữ liệu: FAISS cũng hỗ trợ một số kỹ thuật giảm chiều dữ liệu (dimensionality reduction) để tăng hiệu quả tìm kiếm.
- Khả năng mở rộng (Scalability): Được thiết kế để xử lý hàng triệu hoặc thậm chí hàng tỷ vector trên CPU hoặc GPU.

Cách hoạt động (ví dụ một số phương pháp phổ biến): FAISS cung cấp nhiều loại index khác nhau, mỗi loại có ưu nhược điểm riêng về tốc độ và độ chính xác:

- Flat Index (IndexFlatL2, IndexFlatIP): Tìm kiếm chính xác (brute-force) bằng cách tính khoảng cách/tích vô hướng với tất cả các vector. Nhanh cho tập dữ liệu nhỏ, nhưng chậm với tập lớn.
- Inverted File Index (IVF): Đây là một phương pháp ANN phổ biến. Đầu tiên, các vector được phân cụm thành các centroid. Khi tìm kiếm, truy vấn chỉ cần so sánh với các vector trong một vài cụm gần nhất, thay vì toàn bộ tập dữ liệu. Điều này tăng tốc đáng kể.
- Product Quantization (PQ): Mã hóa vector thành các vector con nhỏ hơn, giúp giảm dung lượng bộ nhớ và tăng tốc độ tính toán khoảng cách. Thường được kết hợp với IVF (ví dụ: IndexIVFPQ).
- Locality Sensitive Hashing (LSH): Một kỹ thuật ANN khác mà hashes các điểm lân cận vào cùng một "thùng" (bucket) với xác suất cao.

Công thức:

Giả sử bạn có một tập hợp các vector $D = \{v_1, v_2, \dots, v_N\}$ và một vector truy vấn q . FAISS sẽ tìm kiếm các vector $v_j \in D$ sao cho $distance(q, v_j)$ (ví dụ: khoảng cách Euclidean $\|q - v_j\|_2$) là nhỏ nhất, hoặc $similarity(q, v_j)$ (ví dụ: độ tương đồng cosine) là lớn nhất.

f. Cross-Attention

Cơ chế Attention (đặc biệt là Scaled Dot-Product Attention) là một thành phần cốt lõi trong kiến trúc Transformer. Nó cho phép mô hình tập trung vào các phần quan trọng của dữ liệu đầu vào khi xử lý. Cross-Attention là một biến thể của attention, nơi "query" đến từ một nguồn (ví dụ: bộ giải mã ngôn ngữ) và "key/value" đến từ một nguồn khác (ví dụ: các đặc trưng hình ảnh).


Chức năng:

Kết nối Visual Features và Caption Decoder: Đây là thành phần cầu nối quan trọng giữa các đặc trưng thị giác (V) từ CLIP-Vision và bộ giải mã ngôn ngữ (GPT-2 Vietnamese Decoder).

Trong mỗi lớp decoder: Trong mỗi lớp của bộ giải mã, thay vì chỉ thực hiện Self-Attention (chỉ tập trung vào các từ đã được sinh ra trước đó trong chuỗi), mô hình còn thực hiện Cross-Attention vào các đặc trưng thị giác (V). Điều này cho phép bộ giải mã "nhìn" vào hình ảnh trong khi đang sinh ra từng từ của chú thích.

Cấu trúc mỗi block attention: Mỗi khối attention trong decoder bao gồm:

- Self-Attention: Xử lý mối quan hệ giữa các từ đã được sinh ra trong chuỗi caption.
- Cross-Attention: Xử lý mối quan hệ giữa các từ trong chuỗi caption hiện tại và các đặc trưng thị giác từ ảnh.
- Feed-forward Network: Một mạng truyền thẳng để biến đổi thêm các đặc trưng sau khi qua attention.



Hình 1: Cross-Attention

Cross-Attention cho phép bộ giải mã ngôn ngữ "chú ý" đến các phần quan trọng của hình ảnh khi nó cần quyết định từ tiếp theo. Điều này đảm bảo rằng chú thích được sinh ra phù hợp với nội dung trực quan của bức ảnh, chứ không chỉ dựa vào ngữ cảnh của các từ đã sinh trước đó. Nó giúp mô hình liên kết các khái niệm ngôn ngữ với các đối tượng và hành động trong hình ảnh.

Công thức attention tổng quát (Scaled Dot-Product Attention):

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

Trong đó:

Q (Query): Đến từ bộ giải mã (decoder). Đây là biểu diễn của từ hoặc trạng thái hiện tại mà bộ giải mã đang xử lý. Nó "hỏi" các thông tin liên quan từ nguồn khác.

K (Key): Đến từ CLIP-Vision embedding (V). Các keys này là các biểu diễn của các phần khác nhau của ảnh.

V (Value): Cũng đến từ CLIP-Vision embedding (V). Các values này chứa thông tin thực tế mà mô hình cần trích xuất từ hình ảnh.

QK^T : Tích vô hướng giữa query và các key, cho biết mức độ tương đồng giữa query và từng key.

$\sqrt{d_k}$: Hệ số chia để tỷ lệ hóa (scaling factor), giúp ổn định gradient trong quá trình huấn luyện khi d_k (chiều của key/query) lớn.

$\text{softmax}(\dots)$: Hàm softmax chuyển đổi các điểm số tương đồng thành phân phối xác suất, chỉ ra mức độ mà query nên "chú ý" đến từng key/value.

Kết quả cuối cùng là tổng có trọng số của các values, trong đó trọng số được xác định bởi phân phối xác suất từ softmax.

g. Các chỉ số đánh giá

BLEU-n (Bilingual Evaluation Understudy)

BLEU là một trong những metric tự động đầu tiên và phổ biến nhất, ban đầu được phát triển để đánh giá chất lượng của bản dịch máy (machine translation). Ý tưởng cơ bản của BLEU là "bản dịch tốt hơn là bản dịch gần hơn với bản dịch của con người". Nó đo lường mức độ trùng khớp của các n-gram (các chuỗi n từ liên tiếp) giữa caption được sinh ra bởi mô hình và một hoặc nhiều caption tham chiếu (reference captions) do con người viết.

Chức năng: Đo lường độ trùng khớp N-gram: BLEU tính toán precision (độ chính xác) của các n-gram trùng khớp. Tức là, nó đếm xem bao nhiêu n-gram trong caption sinh ra cũng xuất hiện trong caption tham chiếu.

N-gram:

- BLEU-1 (Unigram): Chỉ tính trùng khớp của từng từ đơn lẻ.
- BLEU-2 (Bigram): Tính trùng khớp của các cặp từ liên tiếp.
- BLEU-3 (Trigram): Tính trùng khớp của các chuỗi ba từ liên tiếp.
- BLEU-4 (4-gram): Tính trùng khớp của các chuỗi bốn từ liên tiếp.

Modified Precision: Để tránh việc mô hình sinh ra một từ lặp lại nhiều lần để có điểm cao, BLEU sử dụng "modified precision" (độ chính xác đã điều chỉnh). Số lần đếm một n-gram trong caption sinh ra sẽ được "cắt tỉa" (clip) để không vượt quá số lần xuất hiện tối đa của n-gram đó trong bất kỳ caption tham chiếu nào.

Geometric Mean: Các điểm precision cho các n-gram khác nhau (từ BLEU-1 đến BLEU-4) thường được kết hợp bằng cách lấy trung bình nhân (geometric mean).

Brevity Penalty (BP): BLEU áp dụng một "hình phạt độ ngắn" nếu caption được sinh ra ngắn hơn đáng kể so với caption tham chiếu. Điều này khuyến khích mô hình tạo ra các caption đủ dài và đầy đủ thông tin.

Tác dụng: Đánh giá độ sát nghĩa và ngữ pháp: Một điểm BLEU cao cho thấy caption sinh ra không chỉ có các từ khóa đúng mà còn có cấu trúc câu và cụm từ tương tự với caption tham chiếu, gián tiếp cho thấy ngữ pháp và sự mạch lạc tốt.

So sánh hiệu suất mô hình: Vì là một metric phổ biến, BLEU giúp dễ dàng so sánh hiệu suất giữa các mô hình khác nhau trên cùng một tập dữ liệu.

Giá trị càng cao càng tốt: Giá trị BLEU thường nằm trong khoảng từ 0 đến 1 (hoặc 0 đến 100 nếu nhân 100). Giá trị càng cao cho thấy mức độ trùng khớp càng

lớn, tức là caption càng sát nghĩa với caption tham chiếu. Ngay cả 0.6 hoặc 0.7 đã được coi là rất tốt.

Công thức (Tổng quát cho BLEU-N):

$$BLUE = BP \cdot \exp \left(n = \sum_{n=1}^N w_n \log p_n \right) \quad (4)$$

Trong đó:

BP (Brevity Penalty): Hình phạt cho độ ngắn. Nếu độ dài caption sinh (c) nhỏ hơn độ dài hiệu quả của tham chiếu (r), thì $BP = \exp(1 - r/c)$. Ngược lại, $BP=1$.

N : Bậc n-gram tối đa được xét (thường là 4).

w_n : Trọng số cho precision của n-gram bậc n (thường là $1/N$).

p_n : Modified precision của n-gram bậc n .

$$p_n = \frac{\sum_{n\text{-gram} \in \text{Candidate}} \text{Count}_{clipped}(n\text{-gram})}{\sum_{n\text{-gram} \in \text{Candidate}} \text{Count}(n\text{-gram})} \quad (5)$$

Với $\text{Count}_{clipped}(n\text{-gram})$ là số lần xuất hiện của n-gram trong caption sinh, giới hạn bởi số lần xuất hiện tối đa của nó trong bất kỳ caption tham chiếu nào.

Hạn chế: BLEU có thể bỏ qua các từ đồng nghĩa hoặc các cách diễn đạt khác nhau nhưng có cùng ý nghĩa, dẫn đến điểm thấp mặc dù caption vẫn tốt theo đánh giá của con người. Nó cũng không trực tiếp đánh giá ngữ pháp hay sự mạch lạc tổng thể của câu.

METEOR (Metric for Evaluation of Translation with Explicit Ordering)

METEOR được phát triển để khắc phục một số hạn chế của BLEU, đặc biệt là việc BLEU chỉ tập trung vào precision của n-gram và không tính đến recall (độ phủ) hay sự đa dạng về mặt ngữ nghĩa. METEOR cố gắng đánh giá dựa trên sự khớp từ ngữ (exact matches), khớp gốc từ (stem matches), khớp từ đồng nghĩa (synonym matches) và thậm chí cả khớp cụm từ (paraphrase matches).

Chức năng: Căn chỉnh (Alignment): METEOR tạo ra một sự căn chỉnh (mapping) giữa các từ trong caption sinh ra và caption tham chiếu. Sự căn chỉnh này ưu tiên các loại khớp khác nhau.

Các loại khớp:

- Khớp chính xác: Các từ hoàn toàn giống nhau.
- Khớp gốc từ (Stemming): Các từ có cùng gốc (ví dụ: "run", "running", "ran").
- Khớp từ đồng nghĩa: Sử dụng các nguồn tài nguyên từ vựng như WordNet để tìm các từ đồng nghĩa (ví dụ: "big" và "large").

- Khớp cụm từ: Một số phiên bản nâng cao có thể nhận diện các cụm từ có ý nghĩa tương đương.

Cân bằng Precision và Recall: METEOR tính toán cả precision (số từ khớp trên tổng số từ trong caption sinh) và recall (số từ khớp trên tổng số từ trong caption tham chiếu), sau đó kết hợp chúng bằng F-score (thường là harmonic mean).

Hình phạt phân mảnh (Fragmentation Penalty): Để tính đến thứ tự từ và sự trôi chảy của câu, METEOR áp dụng một hình phạt nếu các từ khớp nằm rải rác hoặc không theo đúng thứ tự.

Tác dụng: Phù hợp hơn với caption ngắn và đánh giá ngữ nghĩa: Do xem xét các loại khớp linh hoạt hơn và cân bằng giữa precision/recall, METEOR thường phù hợp hơn BLEU trong việc đánh giá các caption ngắn hoặc khi có nhiều cách diễn đạt hợp lệ cho cùng một nội dung. Nó phản ánh tốt hơn sự tương đồng ngữ nghĩa.

Tương quan tốt hơn với đánh giá của con người: Nhiều nghiên cứu cho thấy METEOR có tương quan tốt hơn với đánh giá của con người so với BLEU, đặc biệt trong các tác vụ sinh văn bản sáng tạo.

Công thức (Tổng quát):

$$METEOR = (1 - Penalty) * F_{mean} \quad (6)$$

Trong đó:

F_{mean} : F-score cân bằng giữa Precision (P) và Recall (R) của unigram matches.

$$P = \frac{\text{Số lượng từ khớp trong candidate}}{\text{Tổng số từ trong candidate}} \quad (7)$$

$$R = \frac{\text{Số lượng từ khớp trong candidate}}{\text{Tổng số từ trong reference}} \quad (8)$$

$$F_{mean} = \frac{10PR}{P+9R} \text{ (thường dùng Beta = 9, đặt trọng số cao hơn cho Recall)}$$

Penalty: Hình phạt cho sự phân mảnh (fragmentation), phụ thuộc vào số lượng khối từ khớp liên tiếp.

CIDEr (Consensus-based Image Description Evaluation)

CIDEr được thiết kế đặc biệt để đánh giá chú thích ảnh. Nó dựa trên ý tưởng rằng một caption chất lượng cao nên có sự đồng thuận cao với nhiều caption tham chiếu được viết bởi con người. CIDEr sử dụng khái niệm TF-IDF (Term Frequency-Inverse Document Frequency) trên các n-gram để gán trọng số cho các n-gram. Các n-gram hiếm và mang tính thông tin cao (thường chỉ xuất hiện trong một số ít caption tham chiếu) sẽ có trọng số cao hơn, trong khi các n-gram phổ biến (xuất hiện trong hầu hết các caption) sẽ có trọng số thấp hơn.

Chức năng:

TF-IDF của N-gram:

- Term Frequency (TF): Tần suất xuất hiện của một n-gram trong một caption cụ thể.
- Inverse Document Frequency (IDF): Đo lường mức độ phổ biến của một n-gram trên toàn bộ tập dữ liệu (corpus). N-gram càng hiếm trên toàn corpus thì IDF càng cao.
- TF-IDF: Kết hợp TF và IDF để tạo ra một trọng số cho mỗi n-gram, phản ánh tầm quan trọng của nó. N-gram độc đáo và mang thông tin sẽ có trọng số cao.

Cosine Similarity: CIDEr tính toán độ tương đồng cosine giữa vector TF-IDF của n-gram từ caption sinh ra và vector TF-IDF trung bình của các n-gram từ tất cả các caption tham chiếu cho cùng một ảnh.

Tính trung bình trên các N-gram: Điểm CIDEr cuối cùng là tổng trung bình của các điểm cosine similarity cho các n-gram có độ dài khác nhau (thường từ unigram đến 4-gram).

Tác dụng:

- Phản ánh mức độ đồng thuận: CIDEr đánh giá mức độ mà caption sinh ra "đồng thuận" với cách mà nhiều người khác nhau mô tả cùng một bức ảnh. Điều này rất quan trọng trong nhiệm vụ captioning, nơi có nhiều cách đúng để mô tả một hình ảnh.
- Ưu tiên các chi tiết quan trọng: Nhờ TF-IDF, CIDEr ưu tiên các n-gram mang tính thông tin và ít phổ biến, giúp đánh giá tốt hơn các chi tiết độc đáo hoặc quan trọng trong ảnh.
- Giá trị ≥ 1.0 là tốt: Do cơ chế tính toán và trọng số TF-IDF, điểm CIDEr thường có xu hướng cao hơn BLEU và METEOR. Một giá trị CIDEr ≥ 1.0 (hoặc 100 nếu nhân 100) thường được coi là rất tốt, cho thấy sự khớp ngữ nghĩa cao với các tham chiếu.
- Tương quan rất tốt với đánh giá của con người: CIDEr được biết đến là metric có tương quan cao nhất với đánh giá của con người trong nhiệm vụ sinh chú thích ảnh.

Công thức (Tổng quát cho CIDEr-n):

$$CIDEr_n(c_i, S_i) = \frac{1}{|S_i|} \sum_{s_{i,j}} \frac{g^n(c_i) * g^n(s_{i,j})}{||g^n(c_i)|| * ||g^n(s_{i,j})||} \quad (9)$$

$$CIDEr_n(c_i, S_i) = \sum_{n=1}^N CIDEr_n(c_i, S_i) \quad (10)$$

Trong đó:

c_i : Caption được sinh ra cho ảnh thứ i.

$S_i = \{s_{i1}, \dots, s_{im}\}$: Tập hợp m caption tham chiếu cho ảnh thứ i.

$g_k^n(x)$: Vector TF-IDF của các n-gram bậc n trong câu x.

$$g_k^n(x) = TF(w_k^n, x) * IDF(w_k^n)$$


Với w_k^n là n-gram thứ k.

$TF(w_k^n, x)$: Tần suất của n-gram w_k^n trong câu x.

$IDF(w_k^n)$: Logarit của tỷ lệ tổng số hình ảnh trên số hình ảnh chứa n-gram w_k^n .

$\|\cdot\|$: Chuẩn L2 của vector.

2.4.2 Kiến trúc mô hình



Hình 2: Kiến trúc mô hình SMALLCAP-Vi

Mục tiêu: Truy xuất các caption mô tả gần nhất với ảnh đầu vào, nhằm cung cấp ngữ cảnh đầu vào hỗ trợ cho mô hình sinh caption.

Thành phần chính:

- Input Image: ảnh đầu vào người dùng chọn.
- CLIP-Vision: Trích xuất image embedding từ ảnh đầu vào bằng backbone ResNet50x64 hoặc ViT-B/32.
- CLIP-Text: Nhận caption từ cơ sở dữ liệu, chuyển thành caption embedding (trích từ mô hình ngôn ngữ của CLIP).
- FAISS: Sử dụng cosine similarity để tính độ tương đồng giữa image embedding và các caption embeddings.
- Kết quả: Truy xuất k caption có độ tương đồng cosine cao nhất để làm prompt.

Ví dụ: ảnh có cosine similarity với các caption là: ["caption_1": 0.67, "caption_2": 0.23, "caption_3": 0.06] → chọn caption_1 làm gợi ý.

Mục tiêu: Sinh một câu mô tả bằng tiếng Việt, tận dụng cả đặc trưng ảnh và caption truy xuất được.

Thành phần mô hình:

CLIP-Vision: Mã hóa ảnh đầu vào và xuất last_hidden_state làm đặc trưng ảnh.

Datastore: Chứa các ảnh và caption tiếng Việt trong tập huấn luyện.

GPT-2 Vietnamese: Mô hình ngôn ngữ gốc tiếng Việt từ NlpHUST (117M tham số). Được thêm 2 khối Cross-Attention để lấy thông tin ảnh từ CLIP.

Cross-Attention: Cầu nối giữa visual features (từ CLIP) và language decoder (GPT-2), giúp mô hình sinh caption dựa trên nội dung ảnh.

Đầu ra ví dụ: "nam vận động viên tennis đang di chuyển ở trên sân".

2.4.3 Huấn luyện mô hình

a. Chuẩn bị dữ liệu

Sử dụng bộ dữ liệu UIT-ViiC được phát triển bởi Trường đại học Công Nghệ Thông Tin – Đại học Quốc gia TP.HCM. Bộ dữ liệu gồm 2 thành phần chính là ảnh và các chú thích bằng ngôn ngữ tiếng Việt cho mỗi ảnh, mỗi ảnh có 5 chú thích tương ứng. Bộ dữ liệu có 3850 ảnh và 19256 caption tương ứng và được chia làm 3 tập Train, Validation và Test.

b. Tiền xử lý dữ liệu

Để huấn luyện SMALLCAP-Vi, bộ chú thích UIT-ViIC gốc (định dạng COCO JSON) cần được chuyển sang định dạng Karpathy split mà SmallCap yêu cầu.

Quy trình thực hiện:

Tải mô hình GPT-2 tiếng Việt: Sử dụng mô hình NlpHUST/gpt2-vietnamese từ HuggingFace.

Chuyển đổi định dạng dữ liệu: Viết script process_coco_file() để:

- Đọc file JSON COCO gốc từ UIT-ViIC.
- Gom caption theo ID ảnh.
- Ánh xạ thành cấu trúc định dạng Karpathy: mỗi entry gồm image_id, filename, split, sentences.
- Sinh ra file dataset_coco.json (~2 MB), tương thích với loader của SmallCap.

```
{'filepath': 'uitvic_train_coco.json',
 'filename': 'COCO_uitvic_train_coco.json_000000489818.jpg',
 'imgid': 489818,
 'cocoId': 489818,
 'sentids': [974, 2330, 18144, 3199, 11780],
 'sentences': [['raw': 'Một bé gái đang đeo găng tay bóng chày cầm quả bóng chày.',
 'tokens': ['một',
 'bé',
 'gái',
 'đang',
 'đeo',
 'găng_tay',
 'bóng',
 'chày',
 'cầm',
 'quả',
 'bóng_chày',
 '.', ''],
 'imgid': 489818,
 'sentid': 974],
 ['raw': 'Một bé gái đang dùng găng tay bóng chày che mặt.',
 'tokens': ['một',
 'bé',
 'gái',
 'đang',
 'dùng',
 'găng_tay',
 'bóng',
 'chày',
 'che',
 'mặt',
 '.', '']]}
```

Hình 3: Định dạng dữ liệu chuẩn Karpathy

c. Huấn luyện mô hình

Sau khi chuẩn bị dữ liệu định dạng Karpathy, nhóm thực hiện các bước sau để huấn luyện và kiểm thử mô hình SMALLCAP-Vi:

Trích xuất đặc trưng ảnh: Đặc trưng ảnh được trích xuất bằng backbone resnet50x64 và lưu thành file .hdf5.

→ File đặc trưng được lưu tại features/val.hdf5 và features/train.hdf5, phục vụ bước huấn luyện và suy luận.

Xây dựng hệ thống truy xuất caption FAISS: Chạy truy xuất caption:

→ Hệ thống tạo file retrieved_caps_resnet50x64.json chứa các caption gần nhất theo embedding ảnh. File này dùng làm đầu vào hỗ trợ cho mô hình sinh caption.

Huấn luyện mô hình

Mô hình được huấn luyện với:

- Text decoder: NlpHUST/gpt2-vietnamese
- Visual encoder: CLIP ViT-B/32
- Prompt có truy xuất caption tương tự từ FAISS

Các tham số quan trọng như batch size, lr, epoch được giữ nguyên như thiết lập mặc định

Trích xuất đặc trưng ảnh:

- Sử dụng CLIP ResNet50x64 hoặc ViT-B/32 để trích xuất đặc trưng.
- Kết quả lưu vào file .hdf5, ví dụ: features/train.hdf5, features/val.hdf5.

Tạo hệ thống FAISS:

- Trích xuất embedding từ caption trong tập huấn luyện.
- Tạo chỉ mục FAISS và lưu file: retrieved_caps_resnet50x64.json. File này được dùng như gợi ý đầu vào (prompt) cho mô hình trong quá trình huấn luyện và suy luận.

Cấu hình huấn luyện:

- Text Decoder: gpt2-vietnamese (giữ nguyên trọng số, chỉ huấn luyện cross-attention và layer norm).
- Visual Encoder: CLIP ViT-B/32 hoặc ResNet50x64 (đóng băng toàn bộ).Prompt augmentation: sử dụng caption truy xuất từ FAISS làm gợi ý trước đầu vào thực.
- Tham số huấn luyện: Batch size: 32, Epoch: 10, Learning rate: 5e-5, Optimizer: AdamW
- Tổng tham số huấn luyện: khoảng 8.7 triệu, tiết kiệm tài nguyên và nhanh convergence.

2.4.4 Thực nghiệm

a. Đánh giá kết quả huấn luyện

Tổng hợp:

Checkpoint	Bleu_1	Bleu_2	Bleu_3	Bleu_4	METEOR	CIDEr
checkpoint-1124	14.86	6.26	2.49	1.28	10.81	2.00
checkpoint-1405	7.95	3.38	0.98	0.00	9.39	1.37
checkpoint-1686	5.32	2.21	0.92	0.00	8.46	0.93
checkpoint-1967	3.45	1.63	0.73	0.00	7.94	0.83
checkpoint-2248	4.05	1.84	0.81	0.00	8.39	1.11
checkpoint-2529	3.18	1.29	0.63	0.00	7.82	0.86
checkpoint-281	22.62	12.76	7.12	4.29	21.72	0.19
checkpoint-2810	3.11	1.28	0.63	0.00	7.95	0.91
checkpoint-562	22.56	11.53	6.26	3.89	18.55	1.34
checkpoint-843	19.83	8.68	3.73	1.85	13.77	2.87

Hình 4:Kết quả huấn luyện

Nhận xét:

Checkpoint	BLEU-4	METEOR	CIDEr	Nhận xét
checkpoint-281	4.29	4.29	0.19	BLEU và METEOR rất cao → caption đúng cấu trúc và đa dạng, nhưng CIDEr thấp → ít trùng lặp với chú thích gốc.
checkpoint-562	3.89	18.55	1.34	Cân bằng tốt giữa BLEU và CIDEr → caption gần nghĩa

				và giống tham chiếu.
checkpoint-843	1.85	13.77	2.87	CIDEr cao nhất → caption rất giống với các chú thích mẫu, nhưng BLEU thấp → có thể do lặp hoặc thiếu đa dạng.
Các checkpoint còn lại	BLEU-4 < 2	METEOR < 12	CIDEr < 1.5	Hiệu suất thấp → mô hình chưa học tốt hoặc chưa khớp dữ liệu.

Lựa chọn checkpoint:

Nếu mục tiêu là caption gần giống nhất với caption thực tế (tức là có nội dung ngữ nghĩa sát với consensus của con người): checkpoint-843 (CIDEr 2.87) là lựa chọn lý tưởng. Điểm CIDEr vượt trội này cho thấy nó nắm bắt được cốt lõi thông tin mà con người thường dùng để mô tả ảnh.

Nếu mục tiêu là caption đa dạng, ngữ pháp tốt (tức là câu văn trôi chảy, có các n-gram phổ biến): checkpoint-281 (BLEU-4 = 4.29, METEOR = 21.72) có vẻ phù hợp hơn, mặc dù cần kiểm tra thêm các ví dụ thực tế để xác nhận chất lượng nội dung.

Nếu muốn cân bằng tốt giữa hai yếu tố trên (cả nội dung và cấu trúc/từ ngữ): checkpoint-562 (CIDEr 1.34, BLEU-4 3.89, METEOR 18.55) là một lựa chọn tuyệt vời. Nó đạt được CIDEr rất tốt (trên 1.0) và vẫn giữ được các chỉ số BLEU/METEOR ở mức chấp nhận được, cho thấy sự cân bằng giữa việc nắm bắt ý nghĩa chính và duy trì chất lượng ngôn ngữ.

→ “Có thể dùng checkpoint-562 làm mô hình chính thức (CIDEr > 1.3, BLEU-4 cao) và checkpoint-843 để minh họa khả năng mô hình học tốt từ FAISS.

b. Thử nghiệm thực tế



Các ảnh tương tự mô tả:

Bức ảnh này mô tả
hai nam vận động viên tennis đang di chuyển ở trên sân .
một nam vận động viên tennis đang di chuyển ở trên sân .
hai nam vận động viên tennis đang thi đấu ở trên sân .
Bức ảnh này mô tả:
'một nam vận động viên tennis đang di chuyển ở trên sân .'

Hình 5: Demo với ảnh có chủ đề tennis

Hình ảnh mô tả rõ ràng một trận đấu tennis đang diễn ra trên sân màu xanh trong một sân vận động lớn đầy khán giả. Có ít nhất hai vận động viên tennis nam đang hoạt động trên sân.

Các chú thích được tạo ra:

Các chú thích được cung cấp là:

hai nam vận_động_viên tennis đang di_chuyển ở trên sân.

một nam vận_động_viên tennis đang di_chuyển ở trên sân .

hai nam vận_động_viên tennis đang thi_đấu ở trên sân .

Kết luận về hiệu suất của mô hình:

Dựa trên những kết quả này, chúng ta có thể đưa ra các kết luận sau về mô hình, có khả năng phản ánh các đặc điểm của "checkpoint-562" hoặc một mô hình cân bằng tốt tương tự như đã thảo luận trước đó:

Khả năng nhận diện đối tượng và hiểu cảnh tốt: Mô hình xác định đúng các đối tượng chính: "vận động viên tennis" và "sân". Nó cũng hiểu bối cảnh của một sự kiện "tennis". Điều này cho thấy khả năng trích xuất đặc trưng hình ảnh mạnh mẽ (có thể từ CLIP-Vision) và ánh xạ hiệu quả các đặc trưng này sang các khái niệm ngôn ngữ.

Khả năng nhận diện hành động hợp lý: Mô hình xác định đúng các hành động như "di chuyển" và "thi đấu". Điều này cho thấy nó có thể suy luận các hoạt động phổ biến liên quan đến các đối tượng được nhận diện trong cảnh.

Khả năng suy luận số lượng (với một số sự không nhất quán):

- Mô hình tạo ra chú thích chỉ rõ "hai nam vận động viên tennis", điều này chính xác đối với các vận động viên có thể nhìn thấy.
- Tuy nhiên, nó cũng tạo ra "một nam vận động viên tennis". Điều này cho thấy một chút không nhất quán hoặc đôi khi không thể đếm chính xác hoặc tập trung vào tất cả các chủ thể liên quan. Đây có thể là một hạn chế trong khả năng phân đoạn và đếm chính xác của bộ mã hóa hình ảnh, hoặc một sự thiên vị trong mô hình ngôn ngữ đối với các mô tả đơn giản hơn.

Cấu trúc ngữ pháp chấp nhận được: Các chú thích được tạo ra có ngữ pháp chính xác và tự nhiên bằng tiếng Việt. Việc sử dụng các từ ghép như vận_động_viên và di_chuyển cho thấy việc mã hóa từ (tokenization) phù hợp và một mô hình ngôn ngữ tiếng Việt được huấn luyện tốt (GPT-2 Vietnamese Decoder).

Tập trung vào các yếu tố chính: Các chú thích tóm tắt hiệu quả hành động và chủ thể chính trong hình ảnh mà không quá chi tiết, đây là một đặc điểm mong muốn cho việc tạo chú thích hình ảnh.

Khả năng tương thích với CIDEr và METEOR (và BLEU chấp nhận được):

- Việc mô hình xác định đúng các yếu tố và hành động chính (vận động viên, sân, di chuyển/thi đấu) cho thấy nó có thể đạt điểm tốt về CIDEr, vì đây là các n-gram "quan trọng" góp phần tạo nên sự đồng thuận giữa các chú thích của

con người. Sự hiện diện của nhiều chú thích liên quan nhưng hơi khác nhau (ví dụ: "di chuyển" so với "thi đấu") cũng phù hợp với trọng tâm của CIDEr về sự trùng lặp ngữ nghĩa.

- Cách diễn đạt mạch lạc và phù hợp nói chung, ngay cả với những thay đổi nhỏ, cho thấy điểm METEOR hợp lý (vì nó xem xét các từ đồng nghĩa và sự gần gũi về ngữ nghĩa).
- Mặc dù không hoàn hảo (do sự khác biệt "một người chơi" so với "hai người chơi"), sự tương đồng trong cách diễn đạt giữa các chú thích được tạo ra và tính đúng đắn chung của chúng ngụ ý rằng điểm BLEU-4 sẽ ở mức chấp nhận được, mặc dù có thể không quá cao do sự khác biệt trong lựa chọn từ cụ thể hoặc sự trùng khớp chính xác của n-gram.

→ Mô hình thể hiện khả năng vững chắc trong việc tạo ra các chú thích liên quan, có ngữ pháp đúng và phù hợp với ngữ cảnh cho hình ảnh đã cho. Nó nhận diện thành công các thực thể và hành động chính. Sự không nhất quán nhỏ trong việc đếm (một so với hai người chơi) là một lĩnh vực nhỏ có thể cải thiện, nhưng nhìn chung, kết quả cho thấy một hệ thống tạo chú thích hình ảnh có khả năng, có thể hưởng lợi từ việc tăng cường truy xuất (retrieval augmentation) như đã mô tả trong bài báo (nơi các chú thích tương tự có thể được truy xuất và sử dụng làm gợi ý).



★ Các caption được truy xuất:
- khán_giả đang theo_dõi trận thi_đấu tennis_nam ở trên sân đất nện ,
- khán_giả đang theo_dõi trận thi_đấu tennis ở trên sân đất nện .
- khán_giả đang theo_dõi một trận thi_đấu tennis đôi nam ở trên sân .
-]

● Bức ảnh này mô tả:
'đấu tennis ở trên sân đất nện.'

Hình 6: Demo với ảnh có chủ đề liên quan đến bóng đá



★ Các caption được truy xuất:

- các cầu thủ bóng chày đang theo dõi đường bay của quả bóng .
- người đàn ông sắp đánh bóng chày trong trò chơi .
- các cầu thủ bóng đá đang đi_chuyển ở trên sân .
- hình ảnh đứa trẻ đang chơi bóng đá trên sân .

🌸 Bức ảnh này mô tả:
'này mô tả các cầu thủ bóng đá đang đi_chuyển ở trên sân .'
🕒 Thời gian xử lý: 0.41 giây

Hình 7: Demo với ảnh có chủ đề bất kỳ



★ Các caption được truy xuất:

- những cậu bé đang luyện tập tennis ở trên sân .
- những cậu bé đang luyện tập tennis ở trên sân .
- những cậu bé đang luyện tập tennis ở ngoài trời .
- những cậu bé đang luyện tập tennis ở ngoài trời .

🌸 Bức ảnh này mô tả:
'những cậu bé đang luyện tập tennis ở ngoài trời . Những cậu bé đang luyện tập tennis ở ngoài trời.'
🕒 Thời gian xử lý: 0.43 giây

Hình 8: Demo với ảnh có chủ đề bóng chày

Nhận xét: Đối với các môn thể thao khác như bóng chày và bóng đá, mô hình thường xuyên sinh ra caption sai, đặc biệt là nhầm lẫn thành "tennis". Ngay cả các caption được truy xuất cũng có xu hướng bị ảnh hưởng bởi từ khóa "tennis" hoặc các môn thể thao khác không chính xác. Điều này cực kỳ rõ ràng trong các ví dụ trên. Khi ảnh không liên quan đến thể thao, các caption được truy xuất đã hoàn toàn không phù hợp, và kết quả là caption sinh ra cũng hoàn toàn sai lệch so với nội dung hình ảnh, nhưng vẫn cố gắng đưa ra một mô tả liên quan đến thể thao.

Kết luận chung về mô hình dựa trên các kết quả này:

Chuyên biệt hóa quá mức vào Tennis: Khi hình ảnh đầu vào là tennis, mô hình hoạt động rất tốt. Các caption sinh ra chính xác, chi tiết và có ngữ pháp tốt. Điều này cho thấy mô hình đã học được các đặc trưng thị giác và ngữ nghĩa liên quan đến tennis một cách hiệu quả.

Thiên vị "Tennis" (Bias towards "Tennis"):

- Trong truy xuất (Retrieval Augmentation): Thành phần Datastore (và khả năng truy xuất của nó) dường như bị chi phối bởi các cặp ảnh-caption về tennis. Ngay cả khi hình ảnh là bóng chày, bóng đá, hoặc không phải thể thao, các caption được truy xuất vẫn thường là về tennis hoặc các môn thể thao khác, chứ không phải các mô tả chính xác về ảnh. Điều này cho thấy không gian nhúng của hình ảnh có thể chưa đủ tốt để phân biệt các môn thể thao khác nhau hoặc các chủ đề hoàn toàn khác biệt.
- Trong sinh caption (GPT-2 Decoder): Dưới sự "dẫn dắt" của các caption truy xuất không phù hợp, cùng với việc mô hình ngôn ngữ đã được "huấn luyện" mạnh mẽ trên dữ liệu tennis, bộ giải mã có xu hướng "áp đặt" từ khóa và ngữ cảnh tennis vào các ảnh khác.

Khả năng khái quát hóa kém: Mô hình gặp khó khăn nghiêm trọng trong việc khái quát hóa ra ngoài chủ đề tennis mà nó đã được huấn luyện nhiều nhất. Điều này thể hiện rõ qua việc nó không thể tạo ra các caption chính xác cho bóng chày, bóng đá hoặc cảnh biển, thay vào đó lại chuyển hướng sang chủ đề "tennis" hoặc các môn thể thao nói chung.

Giải thích:

Tập dữ liệu không cân bằng: Nếu tập dữ liệu có hàng ngàn ảnh tennis và chỉ vài trăm ảnh bóng đá/bóng chày hoặc ảnh phi thể thao, mô hình sẽ dành phần lớn "nỗ lực" học của nó cho chủ đề tennis.

Không gian nhúng: Các nhúng hình ảnh (visual embeddings) của các môn thể thao khác (như bóng đá, bóng chày) hoặc các cảnh không phải thể thao có thể nằm "gần" các nhúng của tennis trong không gian vector mà mô hình đã học, do đó kích hoạt việc truy xuất các caption tennis.

"Prompt" sai: Khi các caption truy xuất làm "prompt" ban đầu đã sai lệch, bộ giải mã ngôn ngữ sẽ khó có thể tự mình tạo ra một mô tả chính xác hoàn toàn.

3. Một số thành phần khác của đồ án

3.1 Kế hoạch dự án

Sprint	Nội dung	Thời gian
1	- Nghiên cứu bài báo SmallCap (CVPR 2023). - Làm quen với kiến trúc encoder-decoder và kỹ thuật Retrieval Augmentation. - Khảo sát dữ liệu UIT-ViIC.	24/04 - 01/05
2	- Chuyển đổi bộ dữ liệu UIT-ViIC sang định dạng COCO JSON để tương thích với pipeline của SmallCap. - Xây dựng chỉ mục FAISS để phục vụ tìm kiếm caption truy xuất.	02/05 - 16/05

3	- Thực hiện fine-tuning mô hình SmallCap với caption tiếng Việt, sử dụng tập huấn luyện đã chuẩn bị. - Huấn luyện trong 3 tuần để mô hình học ổn định.	17/05 - 10/06
4	- Đánh giá kết quả theo các chỉ số BLEU, METEOR và CIDEr. - Tinh chỉnh tham số huấn luyện, lựa chọn checkpoint tốt nhất. - So sánh giữa caption sinh và caption gợi ý.	11/06 - 25/06
5	- Tổng hợp kết quả, phân tích và viết báo cáo. - Chuẩn bị cho buổi thuyết trình và demo mô hình.	26/06 - 04/07

3.2 Đảm bảo thực hiện đúng làm việc nhóm

Dự án được thực hiện theo hình thức làm việc nhóm, tuân thủ các nguyên tắc cộng tác hiệu quả:

Phân công công việc rõ ràng: Mỗi thành viên đảm nhận một mảng cụ thể như xử lý dữ liệu, xây dựng FAISS, fine-tune mô hình, đánh giá kết quả hoặc viết báo cáo.

Làm việc trên cùng hệ thống: Tất cả mã nguồn được chia sẻ và quản lý thông qua Google Colab và GitHub repository để đảm bảo đồng bộ.

Kiểm tra chéo và review định kỳ: Các thành viên kiểm tra lẫn nhau, review kết quả mô hình trước mỗi giai đoạn fine-tune chính thức.

Họp nhóm hàng tuần: Đánh giá tiến độ sprint, cập nhật tình hình và điều chỉnh nếu cần.

3.3 Các vấn đề về đạo đức và làm việc chuyên nghiệp

Dự án tuân thủ nghiêm ngặt các quy định về đạo đức nghiên cứu và tính chuyên nghiệp trong học thuật và công nghệ:

Mã nguồn mở: Tất cả mã code tinh chỉnh mô hình sẽ được công khai trên GitHub cá nhân của nhóm với giấy phép phù hợp.

Trích dẫn đầy đủ nguồn: Paper gốc SmallCap (CVPR 2023) được trích dẫn rõ ràng trong báo cáo và mã nguồn.

Tôn trọng bản quyền dữ liệu: Bộ dữ liệu UIT-ViIC sử dụng là công khai và có giấy phép Creative Commons CC-BY 4.0.

Văn hóa và đạo đức sử dụng dữ liệu: Tránh sử dụng ảnh nhạy cảm; các mô tả sinh ra đều đảm bảo phù hợp với thuần phong mỹ tục và không gây hiểu lầm.

3.4 Tác động xã hội

Mô hình đề xuất không chỉ là một nghiên cứu mang tính học thuật mà còn có tiềm năng ứng dụng rộng rãi:

Hỗ trợ người khiếm thị: Caption tiếng Việt sinh tự động có thể giúp người khiếm thị tiếp cận hình ảnh trên internet hoặc trong tài liệu số.

Quản lý ảnh số và thư viện ảnh: Mô tả ảnh tự động giúp phân loại, tìm kiếm và tổ chức dữ liệu hình ảnh trong các hệ thống lưu trữ.

Gợi ý caption cho SEO: Mô hình có thể dùng để gợi ý nội dung mô tả ảnh trên nền tảng mạng xã hội hoặc website nhằm tối ưu SEO.

Ứng dụng trong giáo dục và nghiên cứu: Hỗ trợ sinh mô tả ảnh trong các dự án học thuật, tài liệu giảng dạy, hoặc dataset annotation.

4. Kết luận

Trong dự án này chúng tôi đã đề xuất SMALL-Vi, một mô hình chú thích ảnh tiếng Việt được tăng cường bằng cơ chế truy xuất, có khả năng huấn luyện nhẹ và có thể chuyển đổi giữa các miền mà không cần huấn luyện lại. Giải pháp này không chỉ giúp cải thiện chất lượng caption đầu ra mà còn đảm bảo khả năng triển khai trên các thiết bị có cấu hình khiêm tốn, phục vụ các nhu cầu ứng dụng thực tế tại Việt Nam. Tuy nhiên do tập dữ liệu được sử dụng là UIT-ViiC do bị mất cân bằng về dữ liệu nên đang bị dự đoán sai lệch trong những trường hợp ảnh đầu vào không có nội dung là môn thể thao tennis. Để khắc phục vấn đề này trong tương lai chúng tôi sẽ tiếp tục phát triển thêm dự án với những ý tưởng như mở rộng kho dữ liệu caption với nhiều hình ảnh và đa dạng chủ đề hơn.

5. Tài liệu tham khảo

- [1] Ramos, R., et al. “*SmallCap: Lightweight Image Captioning Prompted With Retrieval Augmentation.*” *CVPR 2023*.
- [2] Rita Ramos SmallCap GitHub Repository
<https://github.com/RitaRamo/smallcap>
- [3] Lam, Q. H., et al. “*UIT-ViIC: A Dataset for the First Evaluation on Vietnamese Image Captioning.*” *LNAI 2020*.