

ĐẠI HỌC PHENIKAA
TRƯỜNG CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CƠ SỞ

**NGHIÊN CỨU VÀ CẢI TIẾN MÔ HÌNH
NHẬN DẠNG CẢM XÚC GIỌNG NÓI(SER)**

Sinh viên thực hiện:

Họ và tên	MSSV	Email
Đoàn Văn Hiệp	23010739	23010739@st.phenikaa-uni.edu.vn
Phạm Đình Trường	23010136	23010136@st.phenikaa-uni.edu.vn

Giảng viên hướng dẫn: Ts. Nguyễn Thị Thúy An

Hà Nội, tháng 5 năm 2026

LỜI CẢM ƠN

Trước tiên, nhóm sinh viên xin gửi lời cảm ơn chân thành nhất đến Cô hướng dẫn đã tận tình chỉ bảo, định hướng và hỗ trợ nhóm trong suốt quá trình thực hiện đồ án. Những góp ý quý báu của Cô đã giúp nhóm hoàn thiện đề tài một cách tốt nhất.

Nhóm cũng xin cảm ơn Cô trong trường công nghệ thông tin đã truyền đạt những kiến thức nền tảng về trí tuệ nhân tạo, xử lý tín hiệu Số và học sâu, tạo tiền đề vững chắc cho việc thực hiện đồ án này.

Cuối cùng, nhóm xin gửi lời cảm ơn đến gia đình và bạn bè đã luôn động viên, hỗ trợ trong suốt quá trình học tập và nghiên cứu.

*Nhóm sinh viên thực hiện
Đoàn Văn Hiệp, Phạm Đình Trường*

MỤC LỤC

1	Tổng quan	1
1.1	Đặt vấn đề	1
1.2	Mục tiêu đồ án	1
1.2.1	Mục tiêu tổng quát	1
1.2.2	Mục tiêu cụ thể	2
1.3	Phạm vi nghiên cứu	2
1.4	Cấu trúc báo cáo	2
2	Cơ sở lý thuyết	3
2.1	Tổng quan về nhận dạng cảm xúc giọng nói	3
2.2	Xử lý tín hiệu âm thanh số	3
2.2.1	Tín hiệu âm thanh và lấy mẫu	3
2.2.2	Bộ lọc tiền nhấn (Pre-emphasis Filter)	3
2.2.3	Biến đổi Fourier ngắn hạn (STFT)	3
2.2.4	Log-Spectrogram	4
2.3	Mạng nơ-ron tích chập (CNN)	4
2.3.1	Kiến trúc tổng quát	4
2.3.2	AlexNet	5
2.4	Transfer Learning	5
2.4.1	ResNet-18	5
2.4.2	DenseNet-121	5
2.4.3	EfficientNet-B0	6
2.4.4	MobileNet-V2	6
2.5	Hàm lỗi Focal Loss	6
2.6	Kỹ thuật tăng cường dữ liệu EMix	7
2.6.1	EMix-S (Same-class Mixup)	7
2.6.2	EMix-N (Neutral Mixup)	7
2.6.3	EMix-NS (Combined)	7
3	Phương pháp đề xuất	8
3.1	Tổng quan hệ thống	8
3.2	Bộ dữ liệu IEMOCAP	8
3.2.1	Giới thiệu	8
3.2.2	Lọc dữ liệu	9
3.2.3	Thống kê dữ liệu sau lọc	9
3.3	Quy trình tiền xử lý dữ liệu	10
3.3.1	Bước 1: Trích xuất đặc trưng Log-Spectrogram	10
3.3.2	Bước 2: Phân đoạn (Segmentation)	10

3.3.3	Bước 3: Chuẩn hóa và định dạng ảnh đầu vào	11
3.4	Phân chia dữ liệu Speaker-Independent	11
3.5	Kiến trúc mô hình	12
3.6	Quy trình huấn luyện	12
3.6.1	Cấu hình huấn luyện	12
3.6.2	Chiến lược chọn mô hình tốt nhất	12
3.6.3	Chiến lược đánh giá cấp câu nói (Utterance-level)	13
3.7	Các chỉ số đánh giá	13
4	Thực nghiệm và kết quả	14
4.1	Cấu hình thực nghiệm	14
4.2	Kết quả thực nghiệm chính	14
4.2.1	Bảng tổng hợp kết quả	14
4.2.2	Biểu đồ so sánh tổng hợp	15
4.3	Phân tích chi tiết từng mô hình	16
4.3.1	AlexNet Baseline (Cross Entropy, Không Augmentation)	16
4.3.2	AlexNet GAP (Cross Entropy)	17
4.3.3	EfficientNet-B0 (Focal Loss + EMix-S) – Mô hình tốt nhất	18
4.3.4	Các mô hình khác	19
4.4	Phân tích Per-class Accuracy	19
4.5	Ablation Study	21
4.6	5-Fold Speaker-Independent Cross-Validation	22
4.6.1	Mục tiêu	22
4.6.2	Cấu hình các fold	22
4.6.3	Kết quả 5-Fold CV	22
4.6.4	Ví dụ chi tiết: Fold 1	23
4.6.5	So sánh Single Fold vs 5-Fold	23
5	Kết luận và hướng phát triển	25
5.1	Kết luận	25
5.1.1	Về phân tích dữ liệu	25
5.1.2	Về cải tiến mô hình	25
5.1.3	Về kết quả thực nghiệm	25
5.1.4	Tổng kết đóng góp chính	26
5.2	Hạn chế	26
5.3	Hướng phát triển	26
	Tài liệu tham khảo	28
A	Phụ lục	30
A.1	Cấu trúc mã nguồn dự án	30
A.2	Hướng dẫn sử dụng	30

A.2.1	Cài đặt môi trường	30
A.2.2	Huấn luyện mô hình	30
A.2.3	5-Fold Cross-Validation	31
A.2.4	Ablation Study	31
A.2.5	Demo nhận dạng cảm xúc	31
A.2.6	Vẽ biểu đồ so sánh	31
A.3	Tham số dòng lệnh huấn luyện	32
A.4	Danh sách file trọng số mô hình	33

DANH SÁCH HÌNH VẼ

3.1	Sơ đồ tổng quan luồng xử lý dữ liệu và huấn luyện hệ thống	8
3.2	Biểu đồ phân bố mẫu theo nhãn cảm xúc và theo speaker	9
3.3	Phân bố mẫu theo từng speaker trong 5 Session	10
4.1	Biểu đồ so sánh WA và UA giữa các mô hình	15
4.2	Mối quan hệ giữa số lượng tham số và Weighted Accuracy	15
4.3	Biểu đồ tổng hợp kết quả thực nghiệm (publication-quality)	16
4.4	Kết quả AlexNet Baseline: WA=50,73%, UA=25,00%	16
4.5	Kết quả AlexNet GAP + Cross Entropy: WA=78,54%, UA=64,89%	17
4.6	Kết quả EfficientNet-B0 + Focal Loss + EMix-S: WA=80,49%, UA=73,25%	18
4.7	Ma trận nhầm lẫn của các mô hình ResNet-18, DenseNet-121 và MobileNet-V2	19
4.8	Heatmap so sánh per-class accuracy giữa các mô hình	20
4.9	Ma trận nhầm lẫn của cấu hình cơ sở (Config A: EfficientNet-B0 + CE)	21
4.10	Biểu đồ kết quả 5-Fold Cross-Validation	23
4.11	Chi tiết Fold 1 (val=1F, test=1M): WA=80,98%, UA=74,25%	23

DANH SÁCH BẢNG

2.1	Cấu hình tham số STFT	4
3.1	Thống kê phân bố mẫu theo nhãn cảm xúc (cấp câu nói)	9
3.2	Thống kê phân bố mẫu theo nhãn cảm xúc (cấp phân đoạn)	11
3.3	Phân chia dữ liệu theo Speaker-Independent	11
3.4	Danh sách 10 Speaker trong IEMOCAP	11
3.5	Tổng hợp các kiến trúc mô hình	12
3.6	Cấu hình huấn luyện chung	12
4.1	Cấu hình môi trường thực nghiệm	14
4.2	Kết quả thực nghiệm trên tập test (val=1F, test=1M)	14
4.3	Độ chính xác theo từng nhãn cảm xúc (%)	20
4.4	Kết quả Ablation Study – EfficientNet-B0	21
4.5	Cấu hình 5-Fold Cross-Validation	22
4.6	Kết quả 5-Fold Cross-Validation – EfficientNet-B0 + Focal + EMix-S . . .	22
4.7	So sánh phương pháp đánh giá	23
5.1	Tổng kết đóng góp của từng kỹ thuật cải tiến	26
A.1	Danh sách tham số dòng lệnh của <code>train_ser.py</code>	32
A.2	Danh sách file trọng số mô hình đã huấn luyện	33

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Giải thích
SER	Speech Emotion Recognition – Nhận dạng cảm xúc giọng nói
IEMOCAP	Interactive Emotional Dyadic Motion Capture – Bộ dữ liệu cảm xúc đa phương thức
CNN	Convolutional Neural Network – Mạng nơ-ron tích chập
DNN	Deep Neural Network – Mạng nơ-ron sâu
STFT	Short-Time Fourier Transform – Biến đổi Fourier ngắn hạn
WA	Weighted Accuracy – Độ chính xác có trọng số
UA	Unweighted Accuracy – Độ chính xác không trọng số
GAP	Global Average Pooling – Gộp trung bình toàn cục
FC	Fully Connected – Kết nối đầy đủ
FFT	Fast Fourier Transform – Biến đổi Fourier nhanh
dB	Decibel – Đơn vị đo cường độ âm thanh
LR	Learning Rate – Tốc độ học
CV	Cross-Validation – Kiểm thử chéo
EMix	Emotion-aware Mixup – Tăng cường dữ liệu nhận biết cảm xúc
GPU	Graphics Processing Unit – Bộ xử lý đồ họa
VRAM	Video Random Access Memory – Bộ nhớ truy cập ngẫu nhiên video

CHƯƠNG 1: TỔNG QUAN

1.1 Đặt vấn đề

Cảm xúc đóng vai trò quan trọng trong giao tiếp giữa con người. Bên cạnh nội dung ngôn ngữ, giọng nói mang theo các dấu hiệu cảm xúc tinh tế thông qua cao độ (pitch), cường độ (energy), tốc độ nói (speech rate) và chất lượng giọng (voice quality). Việc nhận dạng tự động cảm xúc từ giọng nói – gọi tắt là **SER (Speech Emotion Recognition)** – là một lĩnh vực nghiên cứu đang thu hút sự quan tâm lớn trong cộng đồng khoa học, với nhiều ứng dụng thực tiễn trong các lĩnh vực:

- **Chăm sóc sức khỏe tâm thần:** Phát hiện sớm các dấu hiệu trầm cảm, lo âu thông qua phân tích giọng nói bệnh nhân.
- **Hệ thống tổng đài tự động (Call Center):** Nhận biết cảm xúc khách hàng để điều chỉnh phản hồi phù hợp, nâng cao trải nghiệm người dùng.
- **Trợ lý ảo thông minh:** Giúp các hệ thống AI như Alexa, Siri, Google Assistant phản hồi tự nhiên hơn.
- **An ninh và giám sát:** Phát hiện trạng thái bất thường (tức giận, sợ hãi) trong các cuộc gọi khẩn cấp.
- **Giáo dục và đào tạo:** Đánh giá trạng thái cảm xúc của học sinh trong quá trình học trực tuyến.

Tuy nhiên, bài toán SER đặt ra nhiều thách thức kỹ thuật đáng kể:

1. **Sự mất cân bằng dữ liệu:** Trong thực tế, phân bố cảm xúc rất không đều. Cảm xúc *Neutral* (bình thường) thường chiếm đa số, trong khi cảm xúc *Happiness* (vui vẻ) hoặc *Anger* (tức giận) có số lượng mẫu rất ít.
2. **Sự tương đồng âm học giữa các cảm xúc:** Một số cặp cảm xúc như *Neutral* – *Sadness* có đặc tính âm học rất giống nhau (cùng thuộc nhóm low arousal), gây khó khăn cho việc phân biệt.
3. **Tính phụ thuộc vào người nói:** Mỗi cá nhân có cách biểu đạt cảm xúc khác nhau, đòi hỏi mô hình phải có khả năng tổng quát hóa cao.

1.2 Mục tiêu đồ án

1.2.1 Mục tiêu tổng quát

Nghiên cứu, đánh giá các hạn chế của mô hình nhận dạng cảm xúc giọng nói (SER) hiện tại dựa trên mạng AlexNet và hàm lỗi Cross Entropy trước vấn đề mất cân bằng dữ liệu và đặc tính âm học tương đồng. Từ đó, đề xuất và thực hiện cải tiến hệ thống bằng các kỹ thuật:

- Tăng cường dữ liệu hiện đại (EMix Augmentation).

- Thay thế bằng các kiến trúc học sâu tiên tiến (Transfer Learning: ResNet, DenseNet, EfficientNet, MobileNet).
- Áp dụng hàm lỗi Focal Loss.

nhằm nâng cao độ chính xác tổng thể cũng như độ bền bỉ (robustness) của mô hình trên môi trường đánh giá độc lập người nói (*Speaker-Independent*).

1.2.2 Mục tiêu cụ thể

1. Phân tích chi tiết bộ dữ liệu IEMOCAP và quy trình tiền xử lý dữ liệu.
2. Xây dựng mô hình baseline sử dụng AlexNet + Cross Entropy Loss.
3. Cải tiến kiến trúc mô hình bằng Transfer Learning với 5 kiến trúc CNN khác nhau.
4. Triển khai hàm lỗi Focal Loss để giải quyết vấn đề mất cân bằng dữ liệu.
5. Triển khai kỹ thuật tăng cường dữ liệu EMix (EMix-S, EMix-N, EMix-NS).
6. Thực hiện Ablation Study để đánh giá đóng góp của từng kỹ thuật.
7. Đánh giá thống kê mô hình tốt nhất qua 5-Fold Speaker-Independent Cross-Validation.

1.3 Phạm vi nghiên cứu

- **Bộ dữ liệu:** IEMOCAP (Interactive Emotional Dyadic Motion Capture) – USC, 2008.
- **Dữ liệu sử dụng:** Chỉ sử dụng kênh âm thanh (audio), loại hội thoại ngẫu hứng (improvised).
- **Số lớp cảm xúc:** 4 lớp – Anger (Tức giận), Sadness (Buồn bã), Happiness (Vui vẻ), Neutral (Bình thường).
- **Đặc trưng đầu vào:** Log-Spectrogram (200 băng tần $\times$ 300 khung thời gian).
- **Framework:** PyTorch 1.6+ [10] trên Python 3.10.
- **Phần cứng:** NVIDIA GeForce RTX 3060 (12GB VRAM).

1.4 Cấu trúc báo cáo

Báo cáo được trình bày gồm 5 chương:

- **Chương 1 – Tổng quan:** Giới thiệu bài toán, mục tiêu và phạm vi nghiên cứu.
- **Chương 2 – Cơ sở lý thuyết:** Trình bày nền tảng về xử lý tín hiệu âm thanh, mạng CNN, Transfer Learning, Focal Loss và kỹ thuật EMix.
- **Chương 3 – Phương pháp đề xuất:** Mô tả chi tiết kiến trúc hệ thống, quy trình tiền xử lý và huấn luyện mô hình.
- **Chương 4 – Thực nghiệm và kết quả:** Trình bày kết quả thực nghiệm, phân tích và so sánh các mô hình.
- **Chương 5 – Kết luận và hướng phát triển:** Tóm tắt kết quả, đóng góp và đề xuất hướng phát triển.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về nhận dạng cảm xúc giọng nói

Nhận dạng cảm xúc giọng nói (Speech Emotion Recognition – SER) là bài toán phân loại trạng thái cảm xúc của người nói dựa trên tín hiệu âm thanh [12, 13]. Quá trình này bao gồm ba bước chính: (1) thu thập và tiền xử lý tín hiệu âm thanh, (2) trích xuất đặc trưng (feature extraction), và (3) phân loại cảm xúc bằng mô hình học máy hoặc học sâu.

Các hệ thống SER hiện đại thường sử dụng đặc trưng dạng phổ (spectral features) kết hợp với mạng nơ-ron sâu (DNN/CNN) để đạt hiệu suất cao. Cách tiếp cận phổ biến nhất là chuyển đổi tín hiệu âm thanh thành dạng biểu diễn hình ảnh (spectrogram) rồi áp dụng các kỹ thuật thị giác máy tính (computer vision) để phân loại.

2.2 Xử lý tín hiệu âm thanh số

2.2.1 Tín hiệu âm thanh và lấy mẫu

Âm thanh là sóng cơ học lan truyền trong không khí. Khi số hóa, tín hiệu liên tục được lấy mẫu (sampling) tại tần số cố định. Theo định lý Nyquist, tần số lấy mẫu phải gấp đôi tần số cao nhất cần ghi nhận. Trong đồ án này, tất cả các tệp âm thanh được chuẩn hóa về tần số lấy mẫu $f_s = 16 \text{ kHz}$.

2.2.2 Bộ lọc tiền nhấn (Pre-emphasis Filter)

Bộ lọc tiền nhấn là bộ lọc thông cao bậc nhất, có tác dụng:

- Cân bằng phổ tần số bằng cách khuếch đại dải tần số cao.
- Nhấn mạnh các phụ âm và biểu cảm tinh tế của giọng nói.
- Cải thiện tỉ lệ tín hiệu trên nhiễu (SNR) ở tần số cao.

Công thức toán học:

$$y(t) = x(t) - \alpha \cdot x(t - 1) \quad (2.1)$$

trong đó $\alpha = 0.97$ là hệ số tiền nhấn. Giá trị α gần 1 sẽ nhấn mạnh tần số cao hơn.

2.2.3 Biến đổi Fourier ngắn hạn (STFT)

Biến đổi Fourier ngắn hạn (Short-Time Fourier Transform – STFT) là phương pháp phân tích tín hiệu theo cả miền thời gian và miền tần số. Tín hiệu được chia thành các khung (frame) ngắn, mỗi khung được nhân với hàm cửa sổ rồi thực hiện biến đổi Fourier rời rạc (DFT):

$$X(m, k) = \sum_{n=0}^{L-1} x_{\text{padded}}(n + mH) \cdot e^{-j2\pi kn/N} \quad (2.2)$$

Trong đó, khung tín hiệu gốc có độ dài L được nhân với hàm cửa sổ Hamming $w(n)$ và thực hiện đệm thêm $N - L$ giá trị 0 (zero-padding) để tạo thành chuỗi tín hiệu đệm x_{padded} có độ dài N trước khi tính toán DFT:

$$x_{\text{padded}}(n + mH) = \begin{cases} x(n + mH) \cdot w(n) & \text{với } 0 \leq n < L \\ 0 & \text{với } L \leq n < N \end{cases} \quad (2.3)$$

Các ký hiệu cụ thể bao gồm:

- m là chỉ số khung thời gian.
- k là chỉ số tần số (frequency bin, $0 \leq k < N$).
- L là độ dài khung tín hiệu gốc (trong đề án: $L = 640$ mẫu $\equiv 40$ ms).
- N là độ dài cửa sổ FFT (trong đề án: $N = 800$ điểm).
- H là bước trượt (hop length, trong đề án: $H = 160$ mẫu $\equiv 10$ ms).
- $w(n)$ là hàm cửa sổ Hamming.

Các tham số STFT được cấu hình trong đề án:

Bảng 2.1: Cấu hình tham số STFT

Tham số	Giá trị	Mô tả
Window type	Hamming	Hàm cửa sổ
Window length	40 ms (640 mẫu)	Độ dài mỗi khung
Hop length	10 ms (160 mẫu)	Bước trượt giữa các khung
N_FFT	800 điểm	Số điểm FFT
N_freq	200	Số băng tần số giữ lại

2.2.4 Log-Spectrogram

Phổ biên độ thu được từ STFT được chuyển sang thang đo logarit (decibel) để mô phỏng cách tai người cảm nhận âm lượng:

$$S_{\text{dB}}(m, k) = 20 \cdot \log_{10} (|X(m, k)|) \quad (2.4)$$

Chỉ giữ lại **200 băng tần số thấp nhất** (trong số 401 băng tần của STFT), vì dải tần số dưới 4 kHz chứa hầu hết thông tin ngữ điệu cảm xúc của con người. Kết quả là một ma trận $200 \times T$ cho mỗi câu nói, trong đó T phụ thuộc vào thời lượng câu nói.

2.3 Mạng nơ-ron tích chập (CNN)

2.3.1 Kiến trúc tổng quát

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là loại mạng nơ-ron sâu được thiết kế để xử lý dữ liệu dạng lưới (grid-like data) như ảnh hoặc spectrogram. Kiến trúc cơ bản gồm:

1. **Lớp tích chập (Convolutional Layer):** Áp dụng các bộ lọc (kernel/filter) trượt trên ảnh đầu vào để trích xuất đặc trưng cục bộ.
2. **Lớp gộp (Pooling Layer):** Giảm kích thước không gian của đặc trưng, thường dùng Max Pooling hoặc Average Pooling.
3. **Lớp kết nối đầy đủ (Fully Connected Layer):** Kết hợp các đặc trưng trích xuất để đưa ra quyết định phân loại.

2.3.2 AlexNet

AlexNet [2] là kiến trúc CNN đột phá, gồm 5 lớp tích chập và 3 lớp kết nối đầy đủ. Trong đồ án, AlexNet được sử dụng làm mô hình baseline với hai biến thể:

- **AlexNet Finetuning:** Giữ nguyên kiến trúc gốc, chỉ thay đổi lớp FC cuối cùng. Tổng tham số: 57.02M.
- **AlexNet GAP:** Thay thế 3 lớp FC bằng Global Average Pooling + 1×1 Convolution. Tổng tham số: 2.47M – giảm 96% so với bản gốc.

2.4 Transfer Learning

Transfer Learning là kỹ thuật tận dụng kiến thức đã học từ một tác vụ (thường là ImageNet [9]) để áp dụng cho tác vụ mới. Trong đồ án, các mô hình CNN được khởi tạo bằng trọng số pre-trained trên ImageNet, sau đó fine-tune trên dữ liệu IEMOCAP.

2.4.1 ResNet-18

ResNet [3] giới thiệu kết nối tắt (skip connection / residual connection) cho phép gradient lan truyền ngược trực tiếp qua nhiều lớp, giải quyết vấn đề gradient vanishing:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (2.5)$$

ResNet-18 có 18 lớp trọng số với tổng 11.18M tham số.

2.4.2 DenseNet-121

DenseNet [4] sử dụng liên kết dày đặc (dense connection) – mỗi lớp nhận đầu vào từ tất cả các lớp trước đó:

$$\mathbf{x}_l = H_l([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{l-1}]) \quad (2.6)$$

DenseNet-121 có 121 lớp với tổng 6.96M tham số, giúp khai thác triệt để đặc trưng ở mọi cấp độ.

2.4.3 EfficientNet-B0

EfficientNet [5] tối ưu hóa đồng thời ba chiều: độ sâu (depth), chiều rộng (width) và độ phân giải (resolution) thông qua hệ số compound scaling:

$$\text{depth} : d = \alpha^\phi, \quad \text{width} : w = \beta^\phi, \quad \text{resolution} : r = \gamma^\phi \quad (2.7)$$

với ràng buộc $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. EfficientNet-B0 ($\phi = 1$) có 4.01M tham số – đạt hiệu năng cao nhất trong đề án với số tham số nhỏ.

2.4.4 MobileNet-V2

MobileNet-V2 [6] sử dụng tích chập tách biệt theo chiều sâu (depthwise separable convolution) và khối nghịch đảo residual (inverted residual block) để giảm mạnh số phép tính. Với chỉ 2.23M tham số, MobileNet-V2 phù hợp cho các ứng dụng nhúng trên thiết bị di động.

2.5 Hàm lỗi Focal Loss

Hàm lỗi Cross Entropy truyền thống:

$$\text{CE}(p_t) = -\log(p_t) \quad (2.8)$$

xử lý mọi mẫu như nhau, dẫn đến mô hình bị chi phối bởi lớp đa số.

Focal Loss [7] giải quyết vấn đề này bằng cách thêm hệ số điều chỉnh $(1 - p_t)^\gamma$:

$$\text{FL}(p_t) = -\alpha_t \cdot (1 - p_t)^\gamma \cdot \log(p_t) \quad (2.9)$$

trong đó:

- p_t : Xác suất dự đoán đúng lớp thực.
- $\gamma \geq 0$: Hệ số tập trung (focusing parameter). Giá trị $\gamma = 2.0$ được sử dụng trong đề án.
- α_t : Trọng số cân bằng lớp, được tính tự động dựa trên nghịch đảo tần suất lớp trong tập huấn luyện:

$$\alpha_c = \frac{N_{\text{total}}}{C \times N_c} \quad (2.10)$$

với N_c là số mẫu của lớp c , C là tổng số lớp.

Khi $\gamma > 0$, loss cho các mẫu đã phân loại đúng (có p_t cao) bị giảm mạnh, buộc mô hình tập trung vào các mẫu khó (hard examples) – thường nằm ở các lớp thiểu số.

2.6 Kỹ thuật tăng cường dữ liệu EMix

EMix (Emotion-aware Mixup) là kỹ thuật tăng cường dữ liệu dựa trên MixUp [8], được thiết kế đặc biệt cho bài toán SER. Thay vì trộn ngẫu nhiên hai mẫu bất kỳ, EMix trộn có chiến lược dựa trên nhãn cảm xúc:

2.6.1 EMix-S (Same-class Mixup)

Trộn hai mẫu **cùng nhãn cảm xúc** để củng cố ranh giới phân loại:

$$\tilde{x}_i = \lambda \cdot x_i + (1 - \lambda) \cdot x_j, \quad \text{với } y_i = y_j, \quad \lambda \sim U(0, 1) \quad (2.11)$$

Nhãn đầu ra giữ nguyên: $\tilde{y}_i = y_i$.

2.6.2 EMix-N (Neutral Mixup)

Trộn mẫu cảm xúc mục tiêu với mẫu Neutral như một dạng nhiễu nền, giữ nguyên nhãn mục tiêu:

$$\tilde{x}_i = \lambda \cdot x_i + (1 - \lambda) \cdot x_{\text{neu}}, \quad \lambda \sim U(0.5, 1.0) \quad (2.12)$$

Hệ số $\lambda \geq 0.5$ đảm bảo đặc trưng cảm xúc mục tiêu vẫn chiếm ưu thế.


2.6.3 EMix-NS (Combined)

Kết hợp cả hai phương pháp trên. Với mỗi mini-batch, ngẫu nhiên chọn EMix-N hoặc EMix-S với xác suất bằng nhau ($p = 0.5$).

CHƯƠNG 3: PHƯƠNG PHÁP ĐỀ XUẤT

3.1 Tổng quan hệ thống

Hệ thống nhận dạng cảm xúc giọng nói được xây dựng gồm hai giai đoạn chính: (1) Trích xuất đặc trưng từ tín hiệu âm thanh thô thành Log-Spectrogram, và (2) Huấn luyện mô hình CNN phân loại cảm xúc. Hình 3.1 mô tả tổng quan luồng xử lý dữ liệu.



Hình 3.1: Sơ đồ tổng quan luồng xử lý dữ liệu và huấn luyện hệ thống

Luồng xử lý dữ liệu đầy đủ của hệ thống được mô tả theo sơ đồ sau:

$$\begin{aligned} & \text{.wav (16kHz)} \xrightarrow{\text{Pre-emphasis}} x_{\text{flt}}(t) \xrightarrow{\text{STFT}} A(f, t) \xrightarrow{\text{Log (dB)}} S_{\text{dB}}(200 \times T) \\ & \xrightarrow{\text{Segment + Pad}} (200 \times 300) \xrightarrow{\text{Normalize + 3ch}} (3 \times 200 \times 300) \xrightarrow{\text{Resize + Z-Score}} (3 \times 256 \times 256) \end{aligned}$$

3.2 Bộ dữ liệu IEMOCAP

3.2.1 Giới thiệu

Bộ dữ liệu **IEMOCAP (Interactive Emotional Dyadic Motion Capture)** được thu thập bởi phòng thí nghiệm SAIL thuộc Đại học Nam California (USC), công bố năm 2008 [1]. Đây là bộ dữ liệu chuẩn mực và phổ biến nhất trên thế giới dùng để nghiên cứu nhận dạng cảm xúc đa phương thức.

- **Quy mô:** Khoảng 12 giờ dữ liệu, bao gồm: âm thanh (audio), video khuôn mặt, chuyển động cơ thể (motion capture) và văn bản hội thoại (transcriptions).
- **Đối tượng:** 10 diễn viên chuyên nghiệp (5 Nam, 5 Nữ), chia thành 5 cặp đối thoại theo Session (Session 1 đến Session 5).
- **Kịch bản:**
 - *Improvised (Ngẫu hứng):* Diễn viên diễn xuất tự nhiên dựa trên tình huống giả lập.
 - *Scripted (Kịch bản):* Diễn xuất theo lời thoại viết sẵn.
- **Đánh giá:** Mỗi câu nói được đánh giá bởi ít nhất 3 chuyên gia, nhân cuối cùng theo biểu quyết đa số.

3.2.2 Loại dữ liệu

Để đảm bảo tính tự nhiên và sự tập trung của mô hình, dữ liệu được lọc theo các tiêu chí:


1. **Chỉ lấy dữ liệu ngẫu hứng (Improvised):** Phản ánh chân thực cao độ và ngữ điệu tự nhiên.
2. **Lọc 4 lớp cảm xúc chính:** ang (Anger), sad (Sadness), hap (Happiness), neu (Neutral). Các nhãn không đồng thuận (xxx) hoặc cảm xúc khác bị loại bỏ.
3. **Không gộp nhãn Excited:** Khác với một số nghiên cứu gộp *Excited* vào *Happiness*, đồ án giữ *Happiness* độc lập, làm tăng tính thách thức.

3.2.3 Thống kê dữ liệu sau lọc


Sau khi lọc, tổng số câu nói thu được là **2.280 câu**:

Bảng 3.1: Thống kê phân bố mẫu theo nhãn cảm xúc (cấp câu nói)

Nhãn cảm xúc	Số câu nói	Tỉ lệ (%)	Vai trò
Neutral (Bình thường)	1.099	48,2	Lớp đa số
Sadness (Buồn bã)	608	26,7	–
Anger (Tức giận)	289	12,7	Lớp thiểu số
Happiness (Vui vẻ)	284	12,5	Lớp thiểu số nhất
Tổng cộng	2.280	100,0	



Hình 3.2: Biểu đồ phân bố mẫu theo nhãn cảm xúc và theo speaker



Hình 3.3: Phân bố mẫu theo từng speaker trong 5 Session

Sự chênh lệch giữa lớp đa số (*Neutral*: 48,2%) và lớp thiểu số nhất (*Happiness*: 12,5%) lên đến gần **4 lần**, đặt ra thách thức lớn cho mô hình phân loại.

3.3 Quy trình tiền xử lý dữ liệu

3.3.1 Bước 1: Trích xuất đặc trưng Log-Spectrogram

Quy trình trích xuất đặc trưng được thực hiện qua module `features_extraction/` sử dụng thư viện `librosa` [11]:

1. **Resampling**: Chuẩn hóa tần số lấy mẫu về 16 kHz.
2. **Pre-emphasis**: Áp dụng bộ lọc tiền nhấn với $\alpha = 0.97$.
3. **STFT**: Biến đổi Fourier ngắn hạn với cửa sổ Hamming (40 ms), bước trượt 10 ms, $N_{\text{FFT}} = 800$.
4. **Log-scale**: Chuyển biên độ sang thang decibel.
5. **Lọc tần số**: Giữ lại 200 băng tần số thấp nhất.

3.3.2 Bước 2: Phân đoạn (Segmentation)

Mỗi câu nói có thời lượng khác nhau, tạo ma trận phổ đồ có chiều dài thời gian khác nhau. Để đưa vào CNN, ma trận được chuẩn hóa kích thước:

- Cắt phổ đồ thành các đoạn có kích thước cố định: 200×300 (200 tần số $\times$ 300 khung thời gian $\approx$ 3 giây).
- Câu nói ngắn hơn 300 khung: **Zero padding** (đệm giá trị 0).
- Câu nói dài hơn 300 khung: **Cắt thành nhiều đoạn độc lập**.

Tổng số phân đoạn thu được: **4.436 phân đoạn**.

Bảng 3.2: Thống kê phân bố mẫu theo nhãn cảm xúc (cấp phân đoạn)

Nhãn cảm xúc	Số phân đoạn	Tỉ lệ (%)
Neutral	2.019	45,5
Sadness	1.307	29,5
Anger	585	13,2
Happiness	525	11,8
Tổng cộng	4.436	100,0

3.3.3 Bước 3: Chuẩn hóa và định dạng ảnh đầu vào

1. **Chuẩn hóa MinMax:** Áp dụng `MinMaxScaler` trên tập Train, chuyển dải giá trị từ $[-80 \text{ dB}, 0 \text{ dB}]$ về $[0.0, 1.0]$. Cùng bộ scaler được áp dụng cho tập Val và Test.
2. **Pseudo-RGB:** Lật ngược trục tần số (tần số thấp ở dưới, tần số cao ở trên). Nhân bản 1 kênh thành 3 kênh giống nhau $\rightarrow$ kích thước $(3 \times 200 \times 300)$.
3. **ImageNet preprocessing:**
 - Resize về 256×256 pixels.
 - Chuẩn hóa Z-Score theo ImageNet: Mean = $[0.485, 0.456, 0.406]$, Std = $[0.229, 0.224, 0.225]$

3.4 Phân chia dữ liệu Speaker-Independent

Để đảm bảo mô hình có khả năng tổng quát hóa trên giọng nói lạ (người không có trong tập huấn luyện), dữ liệu được phân chia theo nguyên tắc **Speaker-Independent**:

Bảng 3.3: Phân chia dữ liệu theo Speaker-Independent

Tập dữ liệu	Số speaker	Mô tả
Train	8 speakers (4 sessions)	Huấn luyện mô hình
Validation	1 speaker	Chọn mô hình tốt nhất
Test	1 speaker	Đánh giá cuối cùng

Ví dụ với cấu hình mặc định: **val=1F**, **test=1M**, 8 speakers từ Session 2–5 làm tập huấn luyện, speaker nữ Session 1 (1F) làm validation, speaker nam Session 1 (1M) làm test.

Bảng 3.4: Danh sách 10 Speaker trong IEMOCAP

Session	Speaker ID	Giới tính	Ký hiệu
Session 1	Speaker 1	Nữ / Nam	1F / 1M
Session 2	Speaker 2	Nữ / Nam	2F / 2M
Session 3	Speaker 3	Nữ / Nam	3F / 3M
Session 4	Speaker 4	Nữ / Nam	4F / 4M
Session 5	Speaker 5	Nữ / Nam	5F / 5M

3.5 Kiến trúc mô hình

Tất cả các mô hình được triển khai trong tệp `model.py` và có cùng giao diện (interface):

- **Đầu vào:** Tensor kích thước $(N, 3, 256, 256)$ – batch ảnh Pseudo-RGB đã chuẩn hóa.
- **Đầu ra:** Logits kích thước $(N, 4)$ – chưa qua Softmax.
- **Khởi tạo:** Trọng số ImageNet pre-trained (khi `-pretrained`).
- **Modification:** Chỉ thay đổi lớp phân loại cuối cùng cho 4 lớp cảm xúc.

Bảng 3.5: Tổng hợp các kiến trúc mô hình

Mô hình	Đặc điểm chính	Lớp phân loại	Tham số
AlexNet	5 Conv + 3 FC	FC(4096, 4)	57,02M
AlexNet GAP	5 Conv + GAP	Conv 1×1 + AvgPool	2,47M
ResNet-18	Skip Connection	FC(512, 4)	11,18M
DenseNet-121	Dense Block	FC(1024, 4)	6,96M
EfficientNet-B0	Compound Scaling	FC(1280, 4)	4,01M
MobileNet-V2	Depthwise Conv	FC(1280, 4)	2,23M

3.6 Quy trình huấn luyện

3.6.1 Cấu hình huấn luyện

Bảng 3.6: Cấu hình huấn luyện chung

Tham số	Giá trị
Optimizer	AdamW
Learning rate	10^{-4}
Batch size	64
Epochs	60
Random seed	100
GPU	NVIDIA RTX 3060 (12GB)
Framework	PyTorch

3.6.2 Chiến lược chọn mô hình tốt nhất

Sau mỗi epoch, mô hình được đánh giá trên tập validation. Để giải quyết triệt để vấn đề mất cân bằng lớp, trọng số tương ứng với kết quả **Unweighted Accuracy (UA) cao nhất** trên tập validation được lưu lại (thay vì chọn theo Weighted Accuracy để tránh mô hình bị thiên lệch vào lớp đa số). Sau khi hoàn thành huấn luyện, cấu hình trọng số tốt nhất này được nạp lại để đánh giá trên tập test.

3.6.3 Chiến lược đánh giá cấp câu nói (Utterance-level)

Do mỗi câu nói có thể được chia thành nhiều phân đoạn, việc dự đoán cấp câu nói được thực hiện bằng cách **trung bình hóa xác suất** (log-softmax) của tất cả phân đoạn thuộc cùng một câu nói, sau đó lấy argmax:

$$\hat{y}_u = \arg \max_c \left(\frac{1}{|\mathcal{S}_u|} \sum_{s \in \mathcal{S}_u} \log P(c|s) \right) \quad (3.1)$$

trong đó $\mathcal{S}_u$ là tập các phân đoạn thuộc câu nói u .

3.7 Các chỉ số đánh giá

- **Weighted Accuracy (WA):** Tỷ lệ dự đoán đúng trên tổng số mẫu:

$$WA = \frac{\text{Số dự đoán đúng}}{\text{Tổng số mẫu}} \quad (3.2)$$

- **Unweighted Accuracy (UA):** Trung bình cộng accuracy của từng lớp, không phụ thuộc vào kích thước lớp:

$$UA = \frac{1}{C} \sum_{c=1}^C \frac{\text{Số dự đoán đúng lớp } c}{\text{Tổng số mẫu lớp } c} \quad (3.3)$$

UA phản ánh chính xác hơn khả năng phân loại đồng đều giữa các lớp, đặc biệt quan trọng khi dữ liệu mất cân bằng.

- **Ma trận nhầm lẫn (Confusion Matrix):** Ma trận $C \times C$ hiển thị số lượng mẫu được phân loại đúng/sai giữa các lớp.

CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Cấu hình thực nghiệm

Toàn bộ thực nghiệm được thực hiện trên cùng một cấu hình phần cứng và phần mềm:

Bảng 4.1: Cấu hình môi trường thực nghiệm

Thành phần	Chi tiết
GPU	NVIDIA GeForce RTX 3060 (12GB VRAM)
Python	3.10 (Miniforge / Conda)
Framework	PyTorch 1.6+
Optimizer	AdamW
Learning rate	10^{-4}
Batch size	64
Số epochs	60
Random seed	100
Phân chia dữ liệu	Speaker-Independent (val=1F, test=1M)

Hệ thống tự động lưu các artifact sau mỗi lượt huấn luyện:

- Trọng số mô hình tốt nhất (* .pth).
- Biểu đồ training/validation curves (*_curves .png).
- Ma trận nhầm lẫn dạng heatmap (*_conf .png).

4.2 Kết quả thực nghiệm chính

4.2.1 Bảng tổng hợp kết quả

Bảng 4.2 trình bày kết quả đánh giá trên tập test (Speaker 1M) cho tất cả 6 cấu hình mô hình.


Bảng 4.2: Kết quả thực nghiệm trên tập test (val=1F, test=1M)

#	Mô hình	Loss	Aug.	Params	Test Loss	WA (%)	UA (%)
1	AlexNet (Baseline)	CE	Không	57,02M	1,2138	50,73	25,00
2	AlexNet GAP	CE	Không	2,47M	0,9859	78,54	64,89
3	ResNet-18	Focal	EMix-S	11,18M	0,4541	76,10	64,37
4	DenseNet-121	Focal	EMix-S	6,96M	0,2927	68,78	66,48
5	EfficientNet-B0 *	Focal	EMix-S	4,01M	0,2786	80,49	73,25
6	MobileNet-V2	Focal	EMix-S	2,23M	0,3549	76,59	71,15


* **EfficientNet-B0 + Focal Loss + EMix-S** là mô hình tốt nhất, đạt WA=80,49% và UA=73,25%.

4.2.2 Biểu đồ so sánh tổng hợp


Các biểu đồ trực quan hóa kết quả so sánh giữa các mô hình được thể hiện từ Hình 4.1 đến Hình 4.3. Trong đó, Hình 4.1 biểu diễn độ chính xác WA và UA của cả 6 cấu hình mô hình; Hình 4.2 thể hiện mối quan hệ và sự cân bằng giữa số lượng tham số huấn luyện (model parameters) và Weighted Accuracy; và Hình 4.3 cung cấp cái nhìn tổng hợp (bản in chất lượng cao) về cả độ chính xác tổng thể và độ chính xác chi tiết theo từng lớp cảm xúc.



Hình 4.1: Biểu đồ so sánh WA và UA giữa các mô hình




Hình 4.2: Mối quan hệ giữa số lượng tham số và Weighted Accuracy



Hình 4.3: Biểu đồ tổng hợp kết quả thực nghiệm (publication-quality)

4.3 Phân tích chi tiết từng mô hình

4.3.1 AlexNet Baseline (Cross Entropy, Không Augmentation)



Hình 4.4: Kết quả AlexNet Baseline: WA=50,73%, UA=25,00%

Kết quả chi tiết được minh họa trong Hình 4.4, bao gồm đồ thị huấn luyện và ma trận nhầm lẫn của mô hình AlexNet Baseline.


Nhận xét:

- Mô hình bị **thiên lệch hoàn toàn về lớp đa số** (majority class bias): phân loại toàn bộ các mẫu của tập kiểm thử vào lớp Neutral (lớp chiếm tỷ lệ lớn nhất là 50,73% tổng số mẫu), dẫn đến độ chính xác lớp Neutral đạt 100% trong khi cả 3 lớp còn lại (Anger, Sadness, Happiness) đều đạt 0%.
- UA = 25,00% (tương đương với việc dự đoán ngẫu nhiên cho 4 lớp) phản ánh rằng mô hình hoàn toàn không học được các đặc trưng phân biệt ngữ điệu giữa các cảm xúc

khác nhau.

- **Nguyên nhân:** Việc sử dụng kiến trúc AlexNet gốc có lớp kết nối đầy đủ (FC) quá lớn (57M tham số) gây ra overfitting nghiêm trọng, kết hợp với hàm lỗi Cross Entropy truyền thống không thể điều chỉnh được ảnh hưởng của sự mất cân bằng dữ liệu, khiến mô hình tối ưu hóa bằng cách hội tụ về việc dự đoán lớp đa số Neutral để giảm thiểu giá trị loss trung bình.

4.3.2 AlexNet GAP (Cross Entropy)




Hình 4.5: Kết quả AlexNet GAP + Cross Entropy: WA=78,54%, UA=64,89%

Đồ thị huấn luyện và ma trận nhầm lẫn của mô hình AlexNet GAP được minh họa trong Hình 4.5.

Nhận xét:

- Thay thế lớp FC bằng GAP giúp giảm 96% tham số ($57M \rightarrow 2.47M$), giúp kiểm soát tốt hiện tượng quá khớp và cải thiện WA từ 50,73% lên **78,54%** (+27,81%).
- UA tăng từ 25% lên **64,89%**, chứng tỏ mô hình đã thực sự học được các đặc trưng phân biệt giữa các lớp cảm xúc thay vì đoán mò vào lớp đa số.
- Tuy nhiên, lớp thiểu số Happiness vẫn chỉ đạt 38,46% độ chính xác, cho thấy sự ảnh hưởng tiêu cực của mất cân bằng dữ liệu vẫn tồn tại khi dùng hàm lỗi Cross Entropy.

4.3.3 EfficientNet-B0 (Focal Loss + EMix-S) – Mô hình tốt nhất




Hình 4.6: Kết quả EfficientNet-B0 + Focal Loss + EMix-S: WA=80,49%, UA=73,25%

Đồ thị huấn luyện và ma trận nhầm lẫn của cấu hình tối ưu nhất (EfficientNet-B0 + Focal Loss + EMix-S) được trình bày tại Hình 4.6.


Nhận xét:

- Đạt kết quả tối ưu nhất trên tập kiểm thử đơn lẻ với WA = **80,49%** và UA = **73,25%**.
- Với chỉ **4,01M tham số** (chỉ bằng 7% kích thước của AlexNet gốc), mô hình đạt hiệu suất vượt trội nhờ cơ chế Compound Scaling của EfficientNet.
- Lớp thiếu số nhất Happiness cải thiện vượt bậc từ 0% (Baseline) lên **61,54%**, chứng minh hiệu quả của việc kết hợp hàm loss Focal Loss và kỹ thuật tăng cường đặc trưng EMix.
- Đạt giá trị Test Loss thấp nhất (**0,2786**), xác nhận mô hình có khả năng tổng quát hóa tốt trên phân bố dữ liệu kiểm thử.


4.3.4 Các mô hình khác



(a) ResNet-18: WA=76,10%, UA=64,37%



(b) DenseNet-121: WA=68,78%, UA=66,48%



(c) MobileNet-V2: WA=76,59%, UA=71,15%

Hình 4.7: Ma trận nhầm lẫn của các mô hình ResNet-18, DenseNet-121 và MobileNet-V2


Ma trận nhầm lẫn chi tiết của các mô hình ResNet-18, DenseNet-121 và MobileNet-V2 được thể hiện tương ứng trong Hình 4.7. Qua đó, MobileNet-V2 chứng minh hiệu quả tốt thứ hai với UA đạt 71,15% nhờ sử dụng các khối nghịch đảo Inverted Residuals và Linear Bottlenecks giúp giữ thông tin ngữ điệu hiệu quả.

4.4 Phân tích Per-class Accuracy

Bảng 4.3 trình bày độ chính xác phân loại theo từng nhãn cảm xúc cho tất cả các mô hình.

Bảng 4.3: Độ chính xác theo từng nhãn cảm xúc (%)

Mô hình	Anger	Sadness	Happiness	Neutral	UA (%)
AlexNet (Baseline)	0,00	0,00	0,00	100,00	25,00
AlexNet GAP	84,62	56,41	38,46	80,08	64,89
ResNet-18	84,62	53,85	38,46	80,62	64,37
DenseNet-121	69,23	61,54	53,85	81,30	66,48
EfficientNet-B0 ★	92,31	61,54	61,54	77,62	73,25
MobileNet-V2	84,62	64,10	53,85	81,99	71,15



Hình 4.8: Heatmap so sánh per-class accuracy giữa các mô hình

Bảng 4.3 liệt kê chi tiết kết quả. Biểu đồ heatmap so sánh độ chính xác theo từng lớp được trực quan hóa tại Hình 4.8.

Phân tích chi tiết:

- Neutral (lớp đa số):** Mô hình AlexNet Baseline đạt 100,00% độ chính xác nhưng đó hoàn toàn là do hiện tượng thiên lệch vào lớp đa số (majority class bias). Trái lại, EfficientNet-B0 duy trì độ chính xác cao ổn định ở mức 77,62% mà không bị thiên lệch.
- Anger:** EfficientNet-B0 đạt độ chính xác cao nhất với 92,31%, cải thiện vượt trội so với mức 0,00% của Baseline, chứng minh mô hình đã học được các đặc trưng biên độ lớn của cảm xúc tức giận.
- Happiness (lớp thiểu số nhất):** Độ chính xác được cải thiện vượt bậc từ 0,00% (Baseline) lên 61,54% (EfficientNet-B0), chứng minh hiệu quả thực tế của Focal Loss kết hợp tăng cường dữ liệu EMix-S trong việc giải quyết vấn đề mất cân bằng dữ liệu cực đoan.

4. **Sadness:** Đạt mức độ chính xác 61,54% đối với EfficientNet-B0. Đây vẫn là một trong những lớp khó phân loại nhất do có sự tương đồng đặc trưng âm học rất lớn với lớp Neutral (cùng thuộc nhóm arousal thấp: cao độ thấp, năng lượng âm thanh yếu và tốc độ phát âm chậm).


4.5 Ablation Study

Để đánh giá đóng góp riêng lẻ của từng kỹ thuật cải tiến, thực nghiệm Ablation Study được thực hiện trên EfficientNet-B0 với các cấu hình kết quả cụ thể trên tập kiểm thử được trình bày trong Bảng 4.4.

Bảng 4.4: Kết quả Ablation Study – EfficientNet-B0

Config	Mô hình	Loss	Augmentation	WA (%)	UA (%)
A	EfficientNet-B0	Cross Entropy	Không	74,15	58,46
B	EfficientNet-B0	Focal Loss	Không	77,07	66,83
C	EfficientNet-B0	Focal Loss	EMix-S	80,49	73,25
D	EfficientNet-B0	Focal Loss	EMix-NS	78,54	70,98

Ma trận nhầm lẫn của cấu hình cơ sở (Config A) được thể hiện tại Hình 4.9.



Hình 4.9: Ma trận nhầm lẫn của cấu hình cơ sở (Config A: EfficientNet-B0 + CE)

Phân tích:

- **Config A → B (+Focal Loss):** Khi thay đổi hàm lỗi từ Cross Entropy sang Focal Loss, chỉ số WA tăng 2,92% (từ 74,15% lên 77,07%) và chỉ số UA tăng vượt bậc 8,37% (từ 58,46% lên 66,83%). Kết quả này cho thấy hiệu quả rõ rệt của Focal Loss trong việc giải quyết vấn đề mất cân bằng dữ liệu bằng cách tập trung học các mẫu khó thuộc các lớp thiểu số.
- **Config B → C (+EMix-S):** Tích hợp thêm kỹ thuật tăng cường dữ liệu EMix-S giúp WA tăng thêm 3,42% (đạt 80,49%) và UA tăng thêm 6,42% (đạt 73,25%). EMix-S giúp củng cố ranh giới phân loại bằng cách trộn các mẫu trong cùng một lớp cảm xúc, nâng cao tính tổng quát của mô hình.

- **Config C vs D (EMix-S vs EMix-NS):** Cấu hình trộn cùng lớp (EMix-S) đạt hiệu quả cao hơn cấu hình trộn kết hợp lớp Neutral (EMix-NS) với chênh lệch 1,95% về WA và 2,27% về UA. Điều này có thể được giải thích do EMix-NS đưa thêm đặc trưng của lớp Neutral vào các lớp cảm xúc khác, tạo ra sự mập mờ về đặc trưng ngữ điệu và làm suy giảm hiệu suất phân loại.

4.6 5-Fold Speaker-Independent Cross-Validation

4.6.1 Mục tiêu

Kết quả trên single fold (val=1F, test=1M) có thể bị ảnh hưởng bởi đặc điểm riêng của speaker. Để đánh giá thống kê đáng tin cậy, mô hình tốt nhất (EfficientNet-B0 + Focal Loss + EMix-S) được đánh giá qua **5-Fold Speaker-Independent Cross-Validation**.

4.6.2 Cấu hình các fold


Bảng 4.5: Cấu hình 5-Fold Cross-Validation

Fold	Val Speaker	Test Speaker	Train (8 speakers)
1	1F	1M	Session 2–5
2	2F	2M	Session 1, 3–5
3	3F	3M	Session 1–2, 4–5
4	4F	4M	Session 1–3, 5
5	5F	5M	Session 1–4

4.6.3 Kết quả 5-Fold CV


Bảng 4.6: Kết quả 5-Fold Cross-Validation – EfficientNet-B0 + Focal + EMix-S

Fold	Val	Test	Test Loss	WA (%)	UA (%)
1	1F	1M	0,2792	80,98	74,25
2	2F	2M	0,4978	65,87	65,11
3	3F	3M	1,0062	69,71	61,76
4	4F	4M	1,0272	71,04	57,73
5	5F	5M	1,6825	61,39	52,51
Mean ± Std				69, 80 ± 7, 29	62, 27 ± 8, 18



Hình 4.10: Biểu đồ kết quả 5-Fold Cross-Validation

4.6.4 Ví dụ chi tiết: Fold 1



Hình 4.11: Chi tiết Fold 1 (val=1F, test=1M): WA=80,98%, UA=74,25%

4.6.5 So sánh Single Fold vs 5-Fold

Bảng 4.7: So sánh phương pháp đánh giá

Phương pháp	WA (%)	UA (%)	Độ tin cậy
Single Fold (val=1F, test=1M)	80,49	73,25	Thấp (phụ thuộc speaker)
5-Fold CV Mean $\pm$ Std	69,80 $\pm$ 7,29	62,27 $\pm$ 8,18	Cao (đại diện 10 speakers)

Đồ thị biểu diễn sự biến động kết quả giữa 5 folds được minh họa tại Hình 4.10. Chi tiết đồ thị học tập và ma trận nhầm lẫn của thực nghiệm Fold 1 được trình bày trong Hình 4.11. So sánh chi tiết hiệu năng giữa phương pháp Single Fold và 5-Fold được tổng hợp trong Bảng 4.7.

Phân tích:

- Kết quả trung bình 5-Fold thấp hơn Single Fold khoảng 10%, cho thấy Session 1 (Fold 1) có người nói dễ nhận dạng cảm xúc hơn trung bình của các Session còn lại.
- Độ lệch chuẩn mẫu $WA = 7,29\%$ và $UA = 8,18\%$ phản ánh sự khác biệt đáng kể về giọng nói và phong cách diễn xuất giữa các speaker khác nhau – đây là đặc tính tự nhiên đầy thử thách của bài toán SER.
- Fold 5 (test=5M) cho kết quả thấp nhất ($WA=61,39\%$), có thể do diễn viên nam trong Session 5 có cách biểu đạt cảm xúc khác biệt so với tập huấn luyện.
- **Hạn chế về tính bất đối xứng giới tính trong phân chia fold:** Trong thiết kế thực nghiệm hiện tại của nhóm nghiên cứu, tập validation luôn cố định là người nói Nữ (F) và tập kiểm thử luôn là người nói Nam (M) của mỗi session. Đây là một hạn chế lớn vì mô hình chưa được kiểm thử hiệu năng trên các giọng nói Nữ độc lập. Điều này tạo ra sự thiên lệch trong đánh giá và cần được khắc phục bằng cách sử dụng phân chia chéo Leave-One-Session-Out thực thụ ở các nghiên cứu tiếp theo.
- Kết quả 5-Fold CV mang tính đại diện cao hơn và phù hợp để so sánh với các nghiên cứu khác trên IEMOCAP.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đồ án đã hoàn thành đầy đủ các mục tiêu đề ra, cụ thể:

5.1.1 Về phân tích dữ liệu

- Phân tích chi tiết bộ dữ liệu IEMOCAP với 2.280 câu nói thuộc 4 lớp cảm xúc, chỉ ra sự mất cân bằng nghiêm trọng (lớp Neutral chiếm 48,2% trong khi Happiness chỉ chiếm 12,5%).
- Trình bày quy trình tiền xử lý hoàn chỉnh: từ tín hiệu âm thanh thô $\rightarrow$ Log-Spectrogram $\rightarrow$ ảnh Pseudo-RGB $\rightarrow$ tensor đầu vào CNN.
- Phân tích nguyên nhân nhầm lẫn giữa Neutral và Sadness dưới góc độ xử lý tín hiệu âm thanh.

5.1.2 Về cải tiến mô hình

- Triển khai thành công 6 kiến trúc mô hình (AlexNet, AlexNet GAP, ResNet-18, DenseNet-121, EfficientNet-B0, MobileNet-V2) với Transfer Learning từ ImageNet.
- Triển khai hàm lỗi Focal Loss ($\gamma = 2.0$, α tự động) giải quyết hiệu quả vấn đề mất cân bằng dữ liệu.
- Triển khai 3 biến thể EMix (EMix-S, EMix-N, EMix-NS) cho bài toán SER.

5.1.3 Về kết quả thực nghiệm

- Mô hình tốt nhất **EfficientNet-B0 + Focal Loss + EMix-S** đạt:
 - Single Fold: **WA = 80,49%**, **UA = 73,25%**
 - 5-Fold CV: **WA = 69,80% $\pm$ 7,29%**, **UA = 62,27% $\pm$ 8,18%**
- Cải thiện đáng kể accuracy lớp thiểu số Happiness từ 0% (Baseline) lên **61,54%**.
- Giảm 93% số tham số so với AlexNet gốc (từ 57,02M xuống 4,01M) trong khi đạt hiệu suất vượt trội.
- Ablation Study chứng minh đóng góp bổ sung (additive) của cả Focal Loss và EMix-S.

5.1.4 Tổng kết đóng góp chính

Bảng 5.1: Tổng kết đóng góp của từng kỹ thuật cải tiến

Kỹ thuật	Vai trò	Cải thiện WA	Cải thiện UA
AlexNet GAP	Giảm overfitting	+27,81%	+39,89%
Focal Loss	Xử lý mất cân bằng	+~4–6%	+~10%
EMix-S	Tăng cường dữ liệu	+~3–5%	+~5–8%
EfficientNet-B0	Kiến trúc tối ưu	+~2–4%	+~2–5%

5.2 Hạn chế

1. **Bộ dữ liệu:** Chỉ thử nghiệm trên IEMOCAP – một bộ dữ liệu tiếng Anh, chưa đánh giá trên ngôn ngữ khác (đặc biệt tiếng Việt).
2. **Số lớp cảm xúc:** Chỉ phân loại 4 lớp cơ bản, chưa mở rộng sang các cảm xúc phức tạp hơn.
3. **Biến thiên giữa speakers:** Độ lệch chuẩn 5-Fold CV còn cao (~7–8%), cho thấy mô hình vẫn nhạy cảm với phong cách biểu đạt cá nhân.
4. **Đặc trưng:** Chỉ sử dụng Log-Spectrogram, chưa khai thác các đặc trưng bổ sung như MFCC, pitch, energy contour.
5. **Đa phương thức:** Chưa kết hợp thông tin từ kênh text hoặc video có sẵn trong IEMOCAP.

5.3 Hướng phát triển

1. **Mở rộng bộ dữ liệu:**
 - Thử nghiệm trên các bộ dữ liệu SER khác: RAVDESS, EmoDB, MSP-IMPROV.
 - Thu thập và xây dựng bộ dữ liệu cảm xúc giọng nói tiếng Việt.
2. **Cải tiến kiến trúc mô hình:**
 - Kết hợp CNN với cơ chế Attention (Self-Attention, Multi-Head Attention).
 - Sử dụng kiến trúc Transformer cho bài toán SER (Speech Emotion Transformer).
 - Áp dụng mô hình pre-trained lớn: Wav2Vec 2.0, HuBERT cho trích xuất đặc trưng.
3. **Đa phương thức (Multimodal):**
 - Kết hợp audio + text (transcription) sử dụng Late Fusion hoặc Cross-Modal Attention.
 - Tích hợp thông tin biểu cảm khuôn mặt (video) để tăng độ chính xác.

4. Ứng dụng thực tế:

- Xây dựng hệ thống nhận dạng cảm xúc thời gian thực (real-time SER).
- Tối ưu mô hình MobileNet-V2 (2,23M params) cho triển khai trên thiết bị di động.
- Tích hợp vào hệ thống tổng đài tự động (Call Center) hoặc trợ lý ảo.

5. Cải tiến phương pháp huấn luyện:

- Áp dụng Curriculum Learning: huấn luyện từ mẫu dễ đến mẫu khó.
- Sử dụng Self-supervised Pre-training trên dữ liệu âm thanh không gán nhãn.
- Nghiên cứu Domain Adaptation để chuyển giao kiến thức giữa các ngôn ngữ.

TÀI LIỆU THAM KHẢO

- [1] C. Busso, M. Bulut, C.-C. Lee, A. Kazemzadeh, E. Mower, S. Kim, J. N. Chang, S. Lee, and S. S. Narayanan, “IEMOCAP: Interactive Emotional Dyadic Motion Capture Database,” *Language Resources and Evaluation*, vol. 42, no. 4, pp. 335–359, 2008.
<https://sail.usc.edu/iemocap/>
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 25, 2012.
<https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
<https://arxiv.org/abs/1512.03385>
- [4] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely Connected Convolutional Networks,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4700–4708, 2017.
<https://arxiv.org/abs/1608.06993>
- [5] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *International Conference on Machine Learning (ICML)*, pp. 6105–6114, 2019.
<https://arxiv.org/abs/1905.11946>
- [6] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4510–4520, 2018.
<https://arxiv.org/abs/1801.04381>
- [7] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal Loss for Dense Object Detection,” in *IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
<https://arxiv.org/abs/1708.02002>
- [8] H. Zhang, M. Cissé, Y. N. Dauphin, and D. Lopez-Paz, “mixup: Beyond Empirical Risk Minimization,” in *International Conference on Learning Representations (ICLR)*, 2018.
<https://arxiv.org/abs/1710.09412>

- [9] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A Large-Scale Hierarchical Image Database,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 248–255, 2009.
- [10] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [11] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and Music Signal Analysis in Python,” in *Proceedings of the 14th Python in Science Conference (SciPy)*, pp. 18–25, 2015.
- [12] M. El Ayadi, M. S. Kamel, and F. Karray, “Survey on Speech Emotion Recognition: Features, Classification Schemes, and Databases,” *Pattern Recognition*, vol. 44, no. 3, pp. 572–587, 2011.
- [13] B. W. Schuller, “Speech Emotion Recognition: Two Decades in a Nutshell, Benchmarks, and Ongoing Trends,” *Communications of the ACM*, vol. 61, no. 5, pp. 90–99, 2018.

PHỤ LỤC A: PHỤ LỤC

A.1 Cấu trúc mã nguồn dự án

```
1 speech_emo_recognition/
2 |-- IEMOCAP_logspec200.pkl          # Dataset đặc trưng Log
   Spectrogram
3 |-- train_ser.py                    # Script huấn luyện chính
4 |-- model.py                        # Định nghĩa tất cả kiến trúc mạng
5 |-- data_utils.py                   # Xử lý và tải dữ liệu
6 |-- run_experiments.py              # Chạy thử nghiệm tất cả thực nghiệm
7 |-- crossval_efficientnet.py        # 5-Fold Cross-Validation
8 |-- ablation_study.py               # Ablation study
9 |-- plot_comparison.py              # Vẽ biểu đồ so sánh tổng hợp
10 |-- test_demo.py                   # Demo nhận dạng cảm xúc từ file .
   wav
11 |-- features_extraction/            # Scripts trích xuất đặc trưng
12 |   |-- extract_features.py         # Script trích xuất chính
13 |   |-- features_util.py            # Hàm tiện ích xử lý tín hiệu
14 |   |-- database.py                 # Giao diện bộ dữ liệu IEMOCAP
15 |   |-- noise_wav/                  # File nhiều để augmentation
16 |-- requirements.txt                # Danh sách thư viện Python
17 |-- *.pth                          # Trong số các mô hình đã huấn
   luyện
```

Listing A.1: Cấu trúc thư mục mã nguồn

A.2 Hướng dẫn sử dụng

A.2.1 Cài đặt môi trường

```
1 # Tạo môi trường Conda
2 conda create -n pt310 python=3.10
3 conda activate pt310
4
5 # Cài đặt dependencies
6 pip install -r requirements.txt
```

Listing A.2: Cài đặt môi trường Python

A.2.2 Huấn luyện mô hình

```

1 python train_ser.py IEMOCAP_logspec200.pkl \
2     --ser_model efficientnet \
3     --val_id 1F --test_id 1M \
4     --num_epochs 60 --batch_size 64 --lr 0.0001 \
5     --seed 100 --gpu 1 \
6     --save_label efficientnet_focal_loss \
7     --loss_type focal \
8     --emix emix-s \
9     --pretrained

```

Listing A.3: Lệnh huấn luyện EfficientNet-B0 (mô hình tốt nhất)

A.2.3 5-Fold Cross-Validation

```

1 python crossval_efficientnet.py

```

Listing A.4: Chạy 5-Fold Cross-Validation

A.2.4 Ablation Study

```

1 python ablation_study.py

```

Listing A.5: Chạy Ablation Study

A.2.5 Demo nhận dạng cảm xúc

```

1 python test_demo.py \
2     --model efficientnet \
3     --pth efficientnet_focal_loss.pth \
4     --wav <duong_dan_file_wav>

```

Listing A.6: Demo nhận dạng cảm xúc từ file .wav

A.2.6 Vẽ biểu đồ so sánh

```

1 python -X utf8 plot_comparison.py

```

Listing A.7: Tạo biểu đồ so sánh tổng hợp

Các biểu đồ đầu ra bao gồm:

- `comparison_wa_ua.png` – WA/UA grouped bar chart
- `comparison_per_class.png` – Per-class accuracy heatmap

- `comparison_params_vs_wa.png` – Params vs WA scatter plot
- `summary_figure.png` – Publication-quality summary figure
- `crossval_results.png` – 5-Fold CV results

A.3 Tham số dòng lệnh huấn luyện

Bảng A.1: Danh sách tham số dòng lệnh của `train_ser.py`

Tham số	Mặc định	Mô tả
<code>features_file</code>	(bắt buộc)	Đường dẫn file đặc trưng .pkl
<code>-ser_model</code>	<code>ser_alexnet</code>	Kiến trúc mô hình: alexnet, alexnet_gap, resnet, densenet, efficientnet, mobilenet
<code>-val_id</code>	1F	ID speaker làm validation
<code>-test_id</code>	1M	ID speaker làm test
<code>-num_epochs</code>	200	Số epochs huấn luyện
<code>-batch_size</code>	32	Kích thước mini-batch
<code>-lr</code>	0.0001	Tốc độ học
<code>-seed</code>	100	Random seed
<code>-gpu</code>	1	Sử dụng GPU (1=có, 0=không)
<code>-save_label</code>	None	Nhãn lưu mô hình
<code>-loss_type</code>	ce	Hàm lỗi: ce (Cross Entropy) hoặc focal (Focal Loss)
<code>-emix</code>	None	EMix augmentation: emix-s, emix-n, emix-ns
<code>-pretrained</code>	False	Sử dụng ImageNet pre-trained weights
<code>-oversampling</code>	False	Random oversampling
<code>-mixup</code>	False	MixUp augmentation
<code>-load_model</code>	None	Nạp trọng số mô hình sẵn có

A.4 Danh sách file trọng số mô hình

Bảng A.2: Danh sách file trọng số mô hình đã huấn luyện

File	Mô tả	Kích thước
alexnet_baseline.pth	AlexNet Baseline (CE)	228 MB
alexnet_final.pth	AlexNet Fine-tuned	228 MB
alexnet_gap_cross_entropy.pth	AlexNet GAP (CE)	9.9 MB
alexnet_gap_focal_loss.pth	AlexNet GAP (Focal)	9.9 MB
resnet_focal_loss.pth	ResNet-18 (Focal + EMix-S)	44.8 MB
densenet_focal_loss.pth	DenseNet-121 (Focal + EMix-S)	28.5 MB
efficientnet_focal_loss.pth	EfficientNet-B0 (Focal + EMix-S)	16.4 MB
mobilenet_focal_loss.pth	MobileNet-V2 (Focal + EMix-S)	9.2 MB
efficientnet_focal_cv_fold*.pth	5-Fold CV weights (5 files)	16.4 MB mỗi file